Новосибирский государственный университет

Физический факультет

Основы Вычислительной Физики

Лекции выжившего

Автор: БВО

Лектор: Усов Э. В.

Новосибирск, 2026

Оглавление

Семестр 1. Последний рубеж **3**

0 Вспомогательная литература **4**
- 0.1 Системы счисления: основные обозначения . . . 4
- 0.2 Десятичная система счисления . . . 4
- 0.3 Перевод $q_1 \to q_2$ . . . 6
- 0.4 Дополнительные материалы . . . 10

1 Представление чисел в ЭВМ **11**
- 1.1 Целые числа . . . 11
- 1.2 Числа с плавающей точкой . . . 12

2 Решение нелинейных уравнений **18**
- 2.1 Постановка задачи . . . 18
- 2.2 Изоляция корня . . . 19
- 2.3 Метод дихотомии . . . 20
- 2.4 Метод простых итераций . . . 23
- 2.5 Метод Ньютона . . . 28
- 2.6 Метод секущих . . . 31

3 Численное интегрирование **32**
- 3.1 Постановка задачи . . . 32
- 3.2 Методы прямоугольников . . . 33
- 3.3 Метод трапеций . . . 36
- 3.4 Формула средних . . . 37
- 3.5 Метод Симпсона . . . 39
- 3.6 Метод Рунге . . . 40

4 Аппроксимация и интерполяция **42**
- 4.1 Задача интерполяции . . . 42
- 4.2 Существование и единственность интерполяционного полинома . . . 42
- 4.3 Интерполяционный полином в форме Лагранжа . . . 44
- 4.4 Разделённые разности . . . 45
- 4.5 Интерполяционный полином в форме Ньютона . . . 46
- 4.6 Погрешность интерполяции . . . 47
- 4.7 Численное дифференцирование . . . 50

5 Численное решение обыкновенных дифференциальных уравнений **52**
- 5.1 Задача Коши и равномерная сетка . . . 52
- 5.2 Метод Эйлера . . . 52

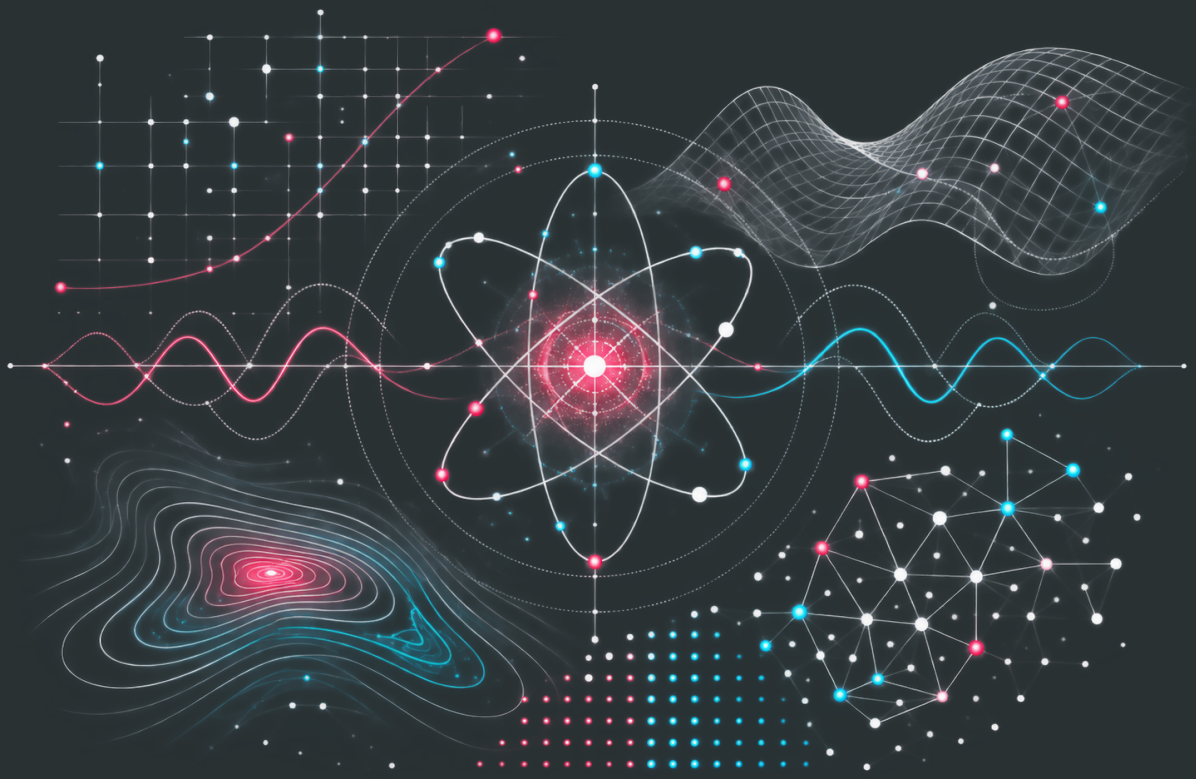
5.3 Модифицированный метод Эйлера 54
5.4 Исправленный метод Эйлера 56
5.5 Методы Рунге–Кутты второго порядка 57
5.6 Классический метод Рунге–Кутты четвёртого порядка 58
5.7 Многошаговый метод Адамса–Башфорта 59
5.8 Устойчивость решения и численной схемы 61
5.9 Устойчивость явной и неявной схем Эйлера 62
5.10 Жёсткие системы дифференциальных уравнений 64

6 Численные методы линейной алгебры 65
6.1 Система линейных алгебраических уравнений 65
6.2 Метод Гаусса 65
6.3 Метод прогонки для трёхдиагональной системы 67
6.4 Степенной метод 70
6.5 Метод вращений Якоби 70

7 Решение уравнения теплопроводности 72
7.1 Разностная схема и её свойства 72
7.2 Уравнение теплопроводности 73
7.3 Конечно-разностная аппроксимация 74
7.4 Порядок аппроксимации 76

Семестр 1

Последний рубеж



Глава 0

Вспомогательная литература

0.1 Системы счисления: основные обозначения

Число в системе с основанием q:

$$(a_n a_{n-1} \dots a_1 a_0 . a_{-1} a_{-2} \dots a_{-m})_q.$$

$$(a_n \dots a_0 . a_{-1} \dots a_{-m})_q = \sum_{k=-m}^{n} a_k q^k, \qquad 0 \le a_k < q.$$

Основание	Система	Цифры	Пример
2	двоичная	$0, 1$	101101_2
8	восьмеричная	$0, \dots, 7$	572_8
10	десятичная	$0, \dots, 9$	935_{10}
16	шестнадцатеричная	$0, \dots, 9, A, \dots, F$	$D6_{16}$

$$A = 10, \qquad B = 11, \qquad C = 12, \qquad D = 13, \qquad E = 14, \qquad F = 15.$$

0.2 Десятичная система счисления

Перевод $q \to 10$

Каждая цифра умножается на соответствующую степень основания:

$$(a_n \dots a_0 . a_{-1} \dots a_{-m})_q = a_n q^n + \dots + a_1 q + a_0 + a_{-1} q^{-1} + \dots + a_{-m} q^{-m}.$$

$2 \to 10$

$$101101.01_2$$

$$= 1 \cdot 2^5 + 0 \cdot 2^4 + 1 \cdot 2^3 + 1 \cdot 2^2 + 0 \cdot 2^1 + 1 \cdot 2^0 + 0 \cdot 2^{-1} + 1 \cdot 2^{-2}$$

$$= 32 + 8 + 4 + 1 + \frac{1}{4} = 45.25_{10}.$$

$8 \to 10$

$$572_8 = 5 \cdot 8^2 + 7 \cdot 8 + 2$$

$$= 320 + 56 + 2 = 378_{10}.$$

$16 \to 10$

$$3A7_{16} = 3 \cdot 16^2 + 10 \cdot 16 + 7$$

$$= 768 + 160 + 7 = 935_{10}.$$

Перевод $10 \to q$

Целая часть

Последовательное деление на q:

$$\begin{aligned} N &= qN_1 + r_0, \\ N_1 &= qN_2 + r_1, \\ N_2 &= qN_3 + r_2, \\ &\vdots \end{aligned} \qquad 0 \le r_i < q.$$

Результат:

$$N_{10} = (r_k r_{k-1} \dots r_1 r_0)_q.$$

Остатки читаются снизу вверх.

Пример:

$$45_{10} \longrightarrow ?_2$$

$$\begin{aligned} 45 &= 2 \cdot 22 + 1, \\ 22 &= 2 \cdot 11 + 0, \\ 11 &= 2 \cdot 5 + 1, \\ 5 &= 2 \cdot 2 + 1, \\ 2 &= 2 \cdot 1 + 0, \\ 1 &= 2 \cdot 0 + 1. \end{aligned}$$

$$45_{10} = 101101_2.$$

Дробная часть

Последовательное умножение на q:

$$qx_i = a_{-(i+1)} + x_{i+1}, \qquad 0 \le x_{i+1} < 1.$$

Целые части читаются сверху вниз.

Пример:

$$0.625_{10} \longrightarrow ?_2$$

$$\begin{aligned} 0.625 \cdot 2 &= 1.25, \\ 0.25 \cdot 2 &= 0.50, \\ 0.50 \cdot 2 &= 1.00. \end{aligned}$$

$$0.625_{10} = 0.101_2.$$

Целая и дробная части

Переводятся отдельно:

$$45.625_{10} = 45_{10} + 0.625_{10}.$$

$$45_{10} = 101101_2, \qquad 0.625_{10} = 0.101_2.$$

$$45.625_{10} = 101101.101_2.$$

0.3 Перевод $q_1 \to q_2$

Перевод $2 \to 8$

Разбить двоичное число на группы по 3 бита, начиная от точки.

000	001	010	011	100	101	110	111
0	1	2	3	4	5	6	7

Целое число

$$11010110_2$$

Дополняем слева нулём:

$$011\ 010\ 110$$

$$011 \longrightarrow 3, \qquad 010 \longrightarrow 2, \qquad 110 \longrightarrow 6.$$

$$11010110_2 = 326_8.$$

Число с дробной частью

Группировка идёт от точки в обе стороны:

$$10110.1011_2$$

$$010\ 110\ .\ 101\ 100$$

$$010 \longrightarrow 2, \qquad 110 \longrightarrow 6,$$

$$101 \longrightarrow 5, \qquad 100 \longrightarrow 4.$$

$$10110.1011_2 = 26.54_8.$$

Перевод $8 \to 2$

Каждую восьмеричную цифру заменить соответствующей тройкой битов:

0	1	2	3	4	5	6	7
000	001	010	011	100	101	110	111

Пример:

$$572_8$$

$$5 \longrightarrow 101, \qquad 7 \longrightarrow 111, \qquad 2 \longrightarrow 010.$$

$$572_8 = 101\ 111\ 010_2.$$

$$572_8 = 101111010_2.$$

Перевод $2 \to 16$

Разбить двоичное число на группы по 4 бита, начиная от точки.

0000	0001	0010	0011	0100	0101	0110	0111
0	1	2	3	4	5	6	7
1000	1001	1010	1011	1100	1101	1110	1111
8	9	A	B	C	D	E	F

Целое число

$$101111100011_2$$

$$1011\ 1110\ 0011$$

$$1011 \longrightarrow B, \qquad 1110 \longrightarrow E, \qquad 0011 \longrightarrow 3.$$

$$101111100011_2 = BE3_{16}.$$

Число с дробной частью

$$101101.1101_2$$

$$0010\ 1101\ .\ 1101$$

$$0010 \longrightarrow 2, \qquad 1101 \longrightarrow D.$$

$$101101.1101_2 = 2D.D_{16}.$$

Перевод $16 \to 2$

Каждую шестнадцатеричную цифру заменить соответствующей четвёркой битов.

0	1	2	3	4	5	6	7
0000	0001	0010	0011	0100	0101	0110	0111
8	9	A	B	C	D	E	F
1000	1001	1010	1011	1100	1101	1110	1111

Пример:

$$D6_{16}$$

$$D \longrightarrow 1101, \qquad 6 \longrightarrow 0110.$$

$$D6_{16} = 1101\ 0110_2.$$

$$D6_{16} = 11010110_2.$$

Перевод $8 \leftrightarrow 16$

Перевод выполняется через двоичную систему.

$8 \to 16$

$$326_8$$

Сначала:

$$3 \longrightarrow 011, \qquad 2 \longrightarrow 010, \qquad 6 \longrightarrow 110.$$

$$326_8 = 011\ 010\ 110_2.$$

Перегруппируем по 4 бита:

$$011010110_2 = 0000\ 1101\ 0110_2.$$

$$1101 \longrightarrow D, \qquad 0110 \longrightarrow 6.$$

$$326_8 = D6_{16}.$$

$16 \to 8$

$$D6_{16}$$

Сначала:

$$D \longrightarrow 1101, \qquad 6 \longrightarrow 0110.$$

$$D6_{16} = 1101\ 0110_2.$$

Перегруппируем по 3 бита:

$$11010110_2 = 011\ 010\ 110_2.$$

$$011 \longrightarrow 3, \qquad 010 \longrightarrow 2, \qquad 110 \longrightarrow 6.$$

$$D6_{16} = 326_8.$$

0.4 Дополнительные материалы

Быстрая таблица перевода

10	2	8	16
0	0000	0	0
1	0001	1	1
2	0010	2	2
3	0011	3	3
4	0100	4	4
5	0101	5	5
6	0110	6	6
7	0111	7	7
8	1000	10	8
9	1001	11	9
10	1010	12	A
11	1011	13	B
12	1100	14	C
13	1101	15	D
14	1110	16	E
15	1111	17	F

Краткий алгоритм выбора перевода

$$
\begin{aligned}
q \to 10 &: \sum_k a_k q^k, \\
10 \to q &: \text{деление / умножение на } q, \\
2 \to 8 &: \text{группы по 3 бита}, \\
8 \to 2 &: \text{каждая цифра } \to 3 \text{ бита}, \\
2 \to 16 &: \text{группы по 4 бита}, \\
16 \to 2 &: \text{каждая цифра } \to 4 \text{ бита}, \\
8 \leftrightarrow 16 &: \text{через двоичную систему}.
\end{aligned}
$$

Полезные степени двойки

n	0	1	2	3	4	5	6	7	8
2^n	1	2	4	8	16	32	64	128	256

n	9	10	11	12	13	14	15	16
2^n	512	1024	2048	4096	8192	16384	32768	65536

$$2^{10} = 1024 \approx 10^3, \qquad 2^{20} \approx 10^6, \qquad 2^{30} \approx 10^9.$$

Глава 1

Представление чисел в ЭВМ

Двоичная арифметика и машинная точность

1.1 Целые числа

Двоичное кодирование

В ЭВМ вся информация хранится в виде последовательности битов. Каждый бит может принимать только два значения:

$$0 \qquad \text{или} \qquad 1.$$

Следовательно, с помощью p бит можно закодировать

$$2^p$$

различных последовательностей.

Чтобы получить из последовательности битов число, каждому биту приписывают свой вес разряда. В привычной десятичной системе веса разрядов справа налево равны $1, 10, 100, \ldots$: например, $305 = 3 \cdot 10^2 + 0 \cdot 10^1 + 5 \cdot 10^0$. В двоичной системе основание равно 2, поэтому веса разрядов справа налево равны $1, 2, 4, 8, \ldots$, то есть степеням двойки.

Рассмотрим последовательность из p битов

$$a_{p-1}a_{p-2}\ldots a_1a_0, \qquad a_i \in \{0, 1\}.$$

Здесь a_i — значение отдельного бита, а i — номер его разряда. Разряды нумеруются **справа налево, начиная с нуля**: a_0 — самый правый бит с весом $2^0 = 1$, a_1 — следующий с весом $2^1 = 2$, и так далее; a_{p-1} — самый левый бит с весом 2^{p-1}. Индекс последнего разряда равен $p-1$, поскольку всего битов p, а отсчёт начинается с нуля. Запись $a_{p-1}\ldots a_0$ означает цифры, поставленные рядом, а не их произведение.

Каждый бит вносит в значение числа слагаемое $a_i 2^i$: если $a_i = 1$, вес этого разряда прибавляется к сумме; если $a_i = 0$, вклад равен нулю. Поэтому значение двоичного числа равно

$$A = a_{p-1}2^{p-1} + a_{p-2}2^{p-2} + \ldots + a_1 2 + a_0 = \sum_{i=0}^{p-1} a_i 2^i.$$

Знак $\sum_{i=0}^{p-1}$ кратко обозначает сложение вкладов всех разрядов: нужно подставить $i = 0, 1, \ldots, p-1$ и сложить полученные слагаемые.

Например, для четырёх битов 1011 имеем $a_3 = 1$, $a_2 = 0$, $a_1 = 1$, $a_0 = 1$. Тогда

$$(1011)_2 = 1 \cdot 2^3 + 0 \cdot 2^2 + 1 \cdot 2^1 + 1 \cdot 2^0 = 8 + 0 + 2 + 1 = 11.$$

Индекс 2 у скобок указывает на двоичную запись; справа получено значение в десятичной системе.

Таким способом кодируются беззнаковые целые числа

$$0, 1, \ldots, 2^p - 1.$$

Например, для $p = 32$ имеется

$$2^{32}$$

различных битовых последовательностей.

Для стандартного 32-битного целого числа

$$4 \text{ байта} \times 8 \text{ бит} = 32 \text{ бита}.$$

Отрицательные числа

Для представления целых чисел со знаком необходимо закодировать как положительные, так и отрицательные значения.

В дополнительном коде отрицательное число $-N$ представляется числом

$$2^p - N.$$

Иными словами, код числа $-N$ выбирается так, чтобы

$$N + (2^p - N) = 2^p \equiv 0 \pmod{2^p}.$$

Поэтому арифметику p-битных целых чисел удобно рассматривать как арифметику по модулю 2^p.

Например,

$$-1 \longleftrightarrow 2^p - 1 = \underbrace{11\ldots11}_{p \text{ бит}}{}_2.$$

Диапазон знаковых p-битных целых чисел имеет вид

$$-2^{p-1} \le N \le 2^{p-1} - 1.$$

Замечание.

Именно поэтому при переполнении целочисленной переменной результат фактически “переходит через границу” доступного диапазона.

1.2 Числа с плавающей точкой

Фиксированная и плавающая точка

Вещественное число можно хранить в форме с фиксированной точкой, заранее задавая положение десятичного разделителя.

Например,

$$1{,}031 = \frac{1031}{1000}, \qquad 10{,}05 = \frac{1005}{100}.$$

Такой способ неудобен для чисел, изменяющихся в очень широком диапазоне. Поэтому на практике используется форма с плавающей точкой:

$$x = M \cdot b^E,$$

где M — мантисса, E — порядок, а b — основание системы счисления.

Например, в десятичной системе

$$1{,}031 = 1{,}031 \cdot 10^0,$$

$$10{,}51 = 1{,}051 \cdot 10^1.$$

Нормализованная форма

Чтобы запись числа с плавающей точкой была однозначной, используется нормализованная форма: положение запятой выбирается так, чтобы перед ней находилась ровно одна ненулевая цифра.

Например,

$$1{,}031 \cdot 10^0$$

является нормализованной записью, тогда как

$$10{,}31 \cdot 10^{-1}$$

описывает то же число, но нормализованной записью не является.

В двоичной системе первая цифра нормализованной мантиссы всегда равна единице. Поэтому число можно записать в форме

$$x = (-1)^S \left(1 + \frac{M}{2^n}\right) 2^E,$$

где

$$S \in \{0, 1\}, \qquad M = 0, 1, \ldots, 2^n - 1.$$

Здесь

- S — бит знака;
- M — целое число, кодирующее дробную часть мантиссы;
- n — число бит дробной части мантиссы;
- E — порядок.

Поскольку старшая единица нормализованной мантиссы всегда известна, её нет необходимости явно хранить в памяти. Это так называемая скрытая единица.

Формат IEEE 754

В памяти нормализованное число записывается в виде трёх полей:

$$\boxed{S} \qquad \boxed{E_S} \qquad \boxed{M},$$

где S — знак, E_S — смещённый порядок, M — дробная часть мантиссы.

Если под порядок выделено w бит, вводится смещение

$$B = 2^{w-1} - 1.$$

Тогда вместо самого порядка E хранится

$$E_S = E + B = E + 2^{w-1} - 1.$$

Следовательно,

$$E = E_S - \left(2^{w-1} - 1\right),$$

и нормализованное число принимает вид

$$x = (-1)^S \left(1 + \frac{M}{2^n}\right) 2^{E_S - (2^{w-1}-1)}.$$

Два значения поля порядка зарезервированы для специальных случаев:

$$E_S = 0, \qquad E_S = 2^w - 1.$$

Поэтому для нормализованных чисел

$$1 \le E_S \le 2^w - 2.$$

Подставляя

$$E_S = E + 2^{w-1} - 1,$$

получаем

$$1 \le E + 2^{w-1} - 1 \le 2^w - 2,$$
$$-2^{w-1} + 2 \le E \le 2^{w-1} - 1.$$

Таким образом,

$$E_{\min} = -2^{w-1} + 2, \qquad E_{\max} = 2^{w-1} - 1.$$

Одинарная точность: `float`

Для формата IEEE 754 binary32, которому обычно соответствует тип `float`,

$$32 = 1 + 8 + 23.$$

Биты распределяются следующим образом:

$$\underbrace{\boxed{S}}_{\text{1 бит}} \quad \underbrace{\boxed{E_S}}_{\text{8 бит}} \quad \underbrace{\boxed{M}}_{\text{23 бита}}.$$

То есть

$$w = 8, \qquad n = 23, \qquad B = 2^7 - 1 = 127.$$

Отсюда

$$E_{\min} = -126, \qquad E_{\max} = 127.$$

Минимальное положительное нормализованное число получается при $M = 0$ и $E = E_{\min}$:

$$f_0 = 2^{E_{\min}} = 2^{-126} \approx 1.18 \cdot 10^{-38}.$$

Следующее машинное число имеет $M = 1$:

$$f_1 = \left(1 + \frac{1}{2^n}\right) 2^{E_{\min}}.$$

Расстояние между ними равно

$$f_1 - f_0 = 2^{E_{\min} - n}.$$

При этом

$$\frac{f_0}{f_1 - f_0} = 2^n.$$

Для `float`, где $n = 23$,

$$2^{23} \approx 8.4 \cdot 10^6.$$

То есть без дополнительного механизма около нуля возникла бы очень большая область непредставимых чисел.

Денормализованные числа

Чтобы заполнить область около нуля, вводятся денормализованные (subnormal) числа.

Для них поле порядка полностью заполнено нулями:

$$E_S = 0.$$

Скрытая единица в мантиссе при этом отсутствует, поэтому число записывается как

$$x = (-1)^S \frac{M}{2^n} 2^{E_{\min}}.$$

Минимальное положительное денормализованное число соответствует $M = 1$:

$$f_{\min}^{\text{denorm}} = 2^{E_{\min} - n}.$$

Максимальное денормализованное число:

$$f_{\max}^{\text{denorm}} = \left(1 - \frac{1}{2^n}\right) 2^{E_{\min}}.$$

А следующее за ним число уже является минимальным нормализованным:

$$f_{\min}^{\text{norm}} = 2^{E_{\min}}.$$

Таким образом, переход от денормализованных чисел к нормализованным происходит без большого разрыва.

Специальные значения

Зарезервированные значения поля порядка позволяют кодировать ноль, бесконечность и `NaN`.

Для краткости обозначим через $00\ldots0$ последовательность из нулей, а через $11\ldots1$ — последовательность из единиц.

1. $$\boxed{S}\,\boxed{00\ldots0}\,\boxed{00\ldots0}$$
   соответствует числу $+0$ или -0 в зависимости от S.

2. $$\boxed{S}\,\boxed{00\ldots0}\,\boxed{M}, \qquad M \neq 0,$$
   соответствует денормализованному числу.

3. $$\boxed{S}\,\boxed{11\ldots1}\,\boxed{00\ldots0}$$
   соответствует
   $$+\infty \qquad \text{или} \qquad -\infty.$$

4. $$\boxed{S}\,\boxed{11\ldots1}\,\boxed{M}, \qquad M \neq 0,$$
   соответствует NaN (*Not a Number*).

5. При
   $$1 \leq E_S \leq 2^w - 2$$
   кодируется обычное нормализованное число.

Машинная точность

Поскольку число бит мантиссы конечно, результат арифметической операции в общем случае приходится округлять до ближайшего представимого машинного числа.

Например,

$$1{,}08 \cdot 2{,}03 = 2{,}1924.$$

Если оставить только три значащие цифры, получим

$$2{,}1924 \longrightarrow 2{,}19,$$

что вносит относительную погрешность порядка

$$10^{-3}.$$

Рассмотрим теперь машинные числа около единицы. При $E = 0$ они имеют вид

$$f = 1 + \frac{M}{2^n}.$$

Два соседних числа:

$$f_0 = 1, \qquad f_1 = 1 + \frac{1}{2^n}.$$

Расстояние между ними равно

$$f_1 - f_0 = \frac{1}{2^n}.$$

Эта величина называется машинным эпсилон:

$$\boxed{\varepsilon = 2^{-n}}.$$

Она характеризует относительное расстояние между соседними машинными числами порядка единицы.

При округлении к ближайшему числу максимальная относительная погрешность имеет порядок

$$\frac{\varepsilon}{2} = 2^{-(n+1)}.$$

Практически машинное эпсилон можно характеризовать условиями

$$\begin{aligned} &1 + \varepsilon \neq 1, \\ &1 + \frac{\varepsilon}{2} = 1 \qquad \text{в машинной арифметике.} \end{aligned}$$

Для одинарной точности

$$\varepsilon_{\texttt{float}} = 2^{-23} \approx 1.19 \cdot 10^{-7},$$

а для двойной точности

$$\varepsilon_{\texttt{double}} = 2^{-52} \approx 2.22 \cdot 10^{-16}.$$

Глава 2

Решение нелинейных уравнений

Методы дихотомии, простых итераций и Ньютона

2.1 Постановка задачи

Будем рассматривать численное решение нелинейного уравнения одной вещественной переменной

$$f(x) = 0.$$

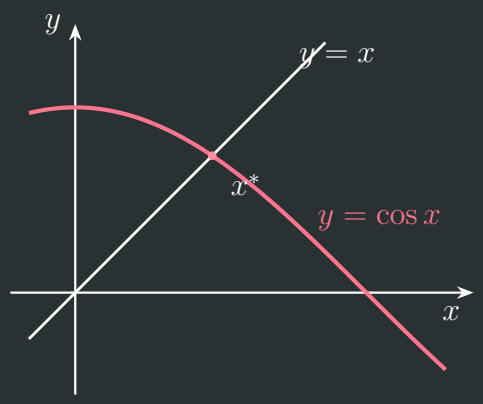
В общем случае такое уравнение не удаётся решить аналитически. Простейший пример — уравнение

$$x = \cos x,$$

которое можно переписать в стандартном виде

$$x - \cos x = 0.$$

Геометрически его корень определяется как точка пересечения графиков $y = x$ и $y = \cos x$.



Геометрическая интерпретация уравнения $x = \cos x$.

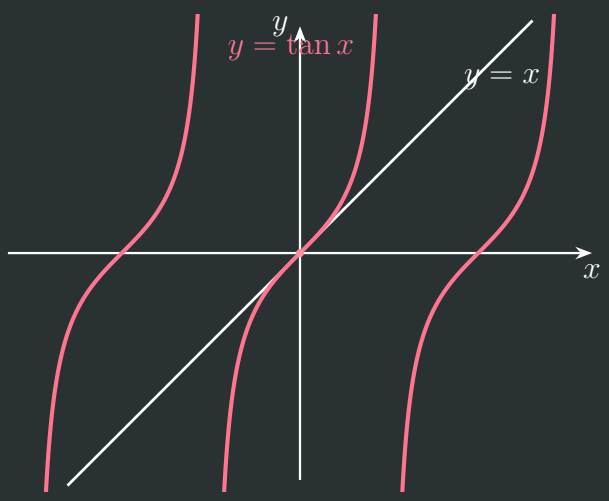
Аналогично уравнение

$$x = \tan x$$

можно записать как

$$x - \tan x = 0.$$

В отличие от предыдущего примера, такое уравнение имеет несколько вещественных корней.



Несколько ветвей $y = \tan x$ и прямая $y = x$.

Таким образом, прежде чем применять численный метод, необходимо выбрать интересующий нас корень и локализовать его на некотором отрезке.

2.2 Изоляция корня

Пусть требуется найти корень x^* уравнения

$$f(x) = 0.$$

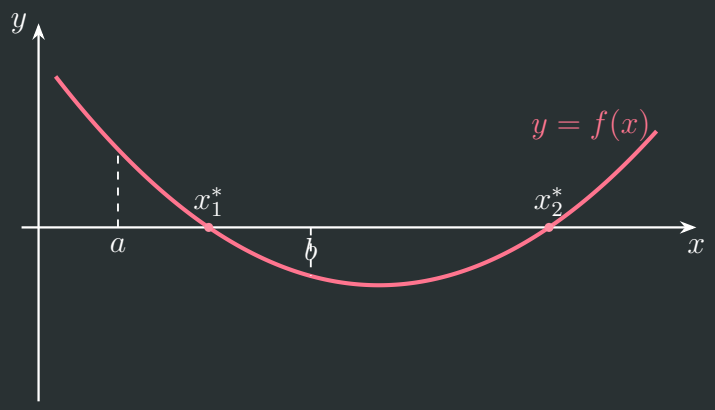
Найдём интервал

$$[a, b],$$

содержащий интересующий нас корень. Будем считать, что на этом интервале выполняются следующие условия:

1) на $[a, b]$ находится только один корень x^*;
2) функция $f(x)$ монотонна на $[a, b]$;
3) функция $f(x)$ непрерывна на $[a, b]$;
4) значения функции на концах имеют разные знаки либо один из концов сам является корнем:
$$f(a)f(b) \leq 0.$$

Для непрерывной функции последнее условие гарантирует существование хотя бы одного корня внутри отрезка. Дополнительное условие единственности позволяет говорить именно об изолированном корне.



Изоляция одного корня на отрезке $[a, b]$.

2.3 Метод дихотомии

Построение последовательности отрезков

Пусть первоначально

$$a_0 = a, \qquad b_0 = b,$$

и

$$f(a_0)f(b_0) \le 0.$$

На первом шаге делим исходный отрезок пополам и вычисляем его середину:

$$x_1 = \frac{a_0 + b_0}{2}.$$

Если

$$f(a_0)f(x_1) \le 0,$$

то выбираем левую половину:

$$a_1 = a_0, \qquad b_1 = x_1.$$

Если же

$$f(a_0)f(x_1) > 0,$$

то корень находится в правой половине и полагаем

$$a_1 = x_1, \qquad b_1 = b_0.$$

В обоих случаях сохраняется условие

$$f(a_1)f(b_1) \le 0,$$

а ширина нового интервала в два раза меньше исходной:

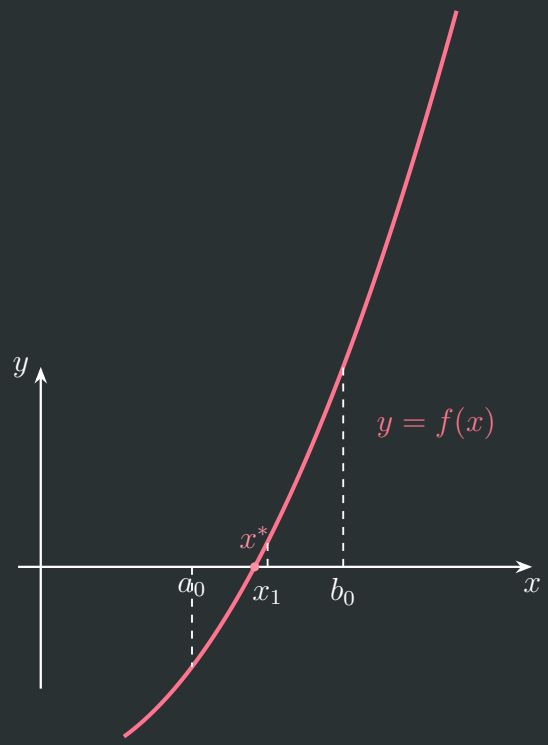
$$b_1 - a_1 = \frac{b_0 - a_0}{2}.$$

Введём обозначение

$$\delta_0 = b_0 - a_0.$$

Тогда

$$\delta_1 = \frac{\delta_0}{2}.$$



Первый шаг метода дихотомии.

На втором шаге повторяем ту же процедуру уже для отрезка $[a_1, b_1]$:

$$x_2 = \frac{a_1 + b_1}{2}.$$

После выбора нужной половины получаем

$$b_2 - a_2 = \delta_2 = \frac{b_0 - a_0}{2^2} = \frac{\delta_0}{2^2}.$$

Продолжая процесс, на n-м шаге имеем

$$x_n = \frac{a_{n-1} + b_{n-1}}{2},$$

а ширина нового интервала равна

$$\begin{aligned} b_n - a_n &= \frac{b_{n-1} - a_{n-1}}{2} \\ &= \frac{b_0 - a_0}{2^n} \\ &= \frac{\delta_0}{2^n}. \end{aligned}$$

Таким образом,

$$\delta_n = \frac{\delta_0}{2^n}.$$

Число шагов

Условием остановки итерационного процесса можно взять достижение заданной точности

$$\delta_n \le \varepsilon.$$

Тогда

$$\frac{\delta_0}{2^N} \le \varepsilon,$$

откуда

$$2^N \ge \frac{\delta_0}{\varepsilon}.$$

Следовательно, необходимое число шагов оценивается как

$$N \approx \log_2 \frac{\delta_0}{\varepsilon} = \frac{\ln(\delta_0/\varepsilon)}{\ln 2}.$$

Если в качестве приближения к корню брать середину текущего интервала, то максимальная абсолютная погрешность вдвое меньше его ширины:

$$|x_n - x^*| \le \frac{b_{n-1} - a_{n-1}}{2}.$$

Сходимость метода

Последовательность левых границ

$$\{a_n\}$$

монотонно возрастает и ограничена сверху. Последовательность правых границ

$$\{b_n\}$$

монотонно убывает и ограничена снизу. Поэтому обе последовательности имеют пределы:

$$a_n \to A, \qquad b_n \to B.$$

Но

$$b_n - a_n = \frac{\delta_0}{2^n} \underset{n\to\infty}{\longrightarrow} 0,$$

следовательно,

$$A = B = C.$$

На каждом шаге сохраняется условие

$$f(a_n) f(b_n) \le 0.$$

Переходя к пределу и используя непрерывность функции $f(x)$, получаем

$$f(C) f(C) \le 0.$$

То есть

$$[f(C)]^2 \leq 0.$$

Поскольку квадрат вещественного числа неотрицателен,

$$f(C) = 0.$$

Следовательно,

$$C = x^*,$$

и

$$x_n = \frac{a_{n-1} + b_{n-1}}{2} \underset{n\to\infty}{\longrightarrow} x^*.$$

Таким образом, метод дихотомии обладает гарантированной сходимостью для непрерывной функции при наличии изменения знака на концах отрезка. Недостаток метода — сравнительно невысокая скорость сходимости.

2.4 Метод простых итераций

Переход к уравнению на неподвижную точку

Исходное уравнение

$$f(x) = 0$$

перепишем в эквивалентном виде

$$x = \varphi(x).$$

Например, простейший вариант такого преобразования имеет вид

$$f(x) = 0 \quad \Longleftrightarrow \quad x + f(x) = x,$$

то есть

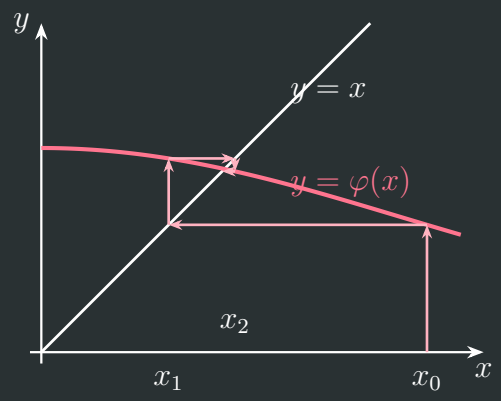
$$\varphi(x) = x + f(x).$$

После этого строим итерационный процесс

$$x_{n+1} = \varphi(x_n), \qquad n = 0, 1, 2, \ldots$$

Выбираем начальное приближение x_0 и последовательно вычисляем

$$x_1 = \varphi(x_0), \qquad x_2 = \varphi(x_1), \qquad x_3 = \varphi(x_2), \ldots$$



Геометрическая схема метода простых итераций.

Условие сходимости

Пусть $[a, b]$ — интервал, содержащий корень x^*, причём

$$\varphi([a, b]) \subset [a, b].$$

Пусть функция $\varphi(x)$ непрерывно дифференцируема на $[a, b]$ и существует число $q < 1$ такое, что

$$|\varphi'(x)| \leq q < 1, \qquad x \in [a, b].$$

Тогда итерационный процесс

$$x_{n+1} = \varphi(x_n)$$

сходится к единственной неподвижной точке x^* на этом интервале.

Действительно, для корня

$$x^* = \varphi(x^*).$$

Поэтому

$$|x_n - x^*| = |\varphi(x_{n-1}) - \varphi(x^*)|.$$

По теореме Лагранжа существует точка ξ_{n-1} между x_{n-1} и x^* такая, что

$$\begin{aligned} |x_n - x^*| &= |\varphi'(\xi_{n-1})||x_{n-1} - x^*| \\ &\leq q|x_{n-1} - x^*|. \end{aligned}$$

Для предыдущего шага аналогично

$$|x_{n-1} - x^*| \leq q|x_{n-2} - x^*|.$$

Следовательно,

$$\begin{aligned} |x_n - x^*| &\leq q^2|x_{n-2} - x^*| \\ &\leq \dots \\ &\leq q^n|x_0 - x^*|. \end{aligned}$$

Так как

$$0 \le q < 1,$$

то

$$q^n \underset{n\to\infty}{\longrightarrow} 0,$$

и поэтому

$$x_n \underset{n\to\infty}{\longrightarrow} x^*.$$

Сходящийся и расходящийся процессы

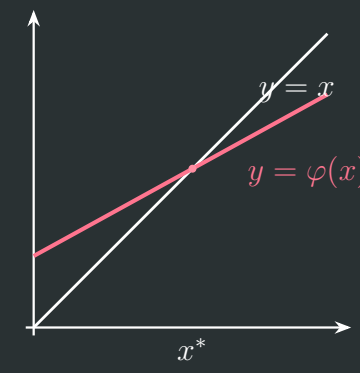
Условие

$$|\varphi'(x)| < 1$$

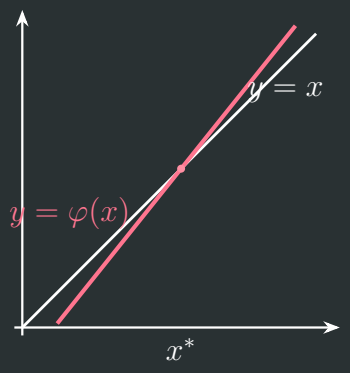
соответствует сжимающему отображению: расстояние до неподвижной точки уменьшается после каждой итерации. Если же в окрестности корня

$$|\varphi'(x^*)| > 1,$$

то неподвижная точка становится отталкивающей и итерации обычно расходятся.



$|\varphi'(x^*)| < 1$: корень притягивает итерации.



$|\varphi'(x^*)| > 1$: корень отталкивает итерации.

Сходящийся и расходящийся итерационные процессы.

Ограничение $|\varphi'| < 1$ является достаточным, но не необходимым условием сходимости. В более общем случае достаточно, чтобы само отображение уменьшало расстояние до искомой неподвижной точки.

Скорость сходимости

Пусть начальное приближение x_0 уже достаточно близко к корню. Разложим $\varphi(x_0)$ около x^*:

$$\varphi(x_0) \approx \varphi(x^*) + \varphi'(x^*)(x_0 - x^*).$$

Так как

$$\varphi(x^*) = x^*,$$

то

$$x_1 - x^* \approx \varphi'(x^*)(x_0 - x^*).$$

Введём абсолютную погрешность

$$\delta_n = |x_n - x^*|.$$

Тогда

$$\delta_1 \approx |\varphi'(x^*)|\,\delta_0.$$

На следующем шаге

$$\delta_2 \approx |\varphi'(x^*)|\,\delta_1 \approx |\varphi'(x^*)|^2\delta_0.$$

Продолжая,

$$\delta_n \approx |\varphi'(x^*)|^n\delta_0.$$

Если требуется достичь точности ε, то

$$\varepsilon \approx |\varphi'(x^*)|^N\delta_0.$$

Следовательно,

$$N \approx \frac{\ln(\delta_0/\varepsilon)}{-\ln|\varphi'(x^*)|}.$$

Сравнивая эту оценку с методом дихотомии, получаем, что метод простых итераций сходится быстрее при

$$|\varphi'(x^*)| < \frac{1}{2}.$$

Особенно быстрой будет сходимость при

$$\varphi'(x^*) = 0,$$

однако в этом случае линейная оценка уже недостаточна и необходимо учитывать следующие члены разложения Тейлора.

Переход к обратной функции

Если

$$|\varphi'(x)| > 1,$$

то прямой итерационный процесс

$$x_{n+1} = \varphi(x_n)$$

может расходиться. Если обратную функцию удобно вычислять, можно перейти от

$$x = \varphi(x)$$

к эквивалентному уравнению

$$x = \varphi^{-1}(x).$$

При этом

$$(\varphi^{-1})'(x) = \frac{1}{\varphi'(\varphi^{-1}(x))}.$$

В окрестности неподвижной точки

$$|(\varphi^{-1})'(x^*)| = \frac{1}{|\varphi'(x^*)|} < 1,$$

так что итерации для обратной функции становятся сходящимися.

Корректирующий множитель

Вместо простейшего представления

$$x = x + f(x)$$

можно использовать эквивалентное уравнение

$$x = x - \lambda f(x), \qquad \lambda \neq 0.$$

Определим

$$\widetilde{\varphi}(x) = x - \lambda f(x).$$

Тогда

$$\widetilde{\varphi}'(x) = 1 - \lambda f'(x).$$

Для сходимости достаточно потребовать

$$|1 - \lambda f'(x)| < 1.$$

Раскрывая это неравенство,

$$-1 < 1 - \lambda f'(x) < 1,$$
$$-2 < -\lambda f'(x) < 0,$$

то есть

$$0 < \lambda f'(x) < 2.$$

Поэтому знак λ следует выбирать совпадающим со знаком $f'(x)$. Если производная не меняет знак на всём рабочем интервале, то достаточное условие можно записать как

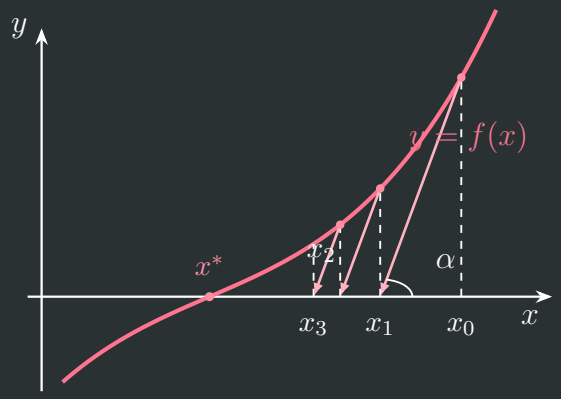
$$0 < |\lambda| < \frac{2}{\max\limits_{x \in [a,b]} |f'(x)|}.$$

При этом для ускорения сходимости значение λ желательно выбирать как можно ближе к

$$\frac{1}{f'(x^*)}.$$

Итерационный процесс принимает вид

$$x_{n+1} = x_n - \lambda f(x_n).$$



Метод простых итераций с корректирующим множителем: несколько последовательных шагов при постоянном λ. Все наклонные отрезки имеют одинаковый наклон $\tan\alpha = 1/\lambda$.

Если угол прямой с осью x обозначить через α, то

$$\tan\alpha = \frac{1}{\lambda}.$$

Именно эта геометрическая интерпретация приводит к следующему ускорению метода: вместо прямой с постоянным наклоном будем на каждом шаге использовать касательную к графику $y = f(x)$.

2.5 Метод Ньютона

Формула метода

Для касательной к графику $y = f(x)$ в точке x_n имеем

$$\tan\alpha = f'(x_n).$$

Сравнивая это с

$$\tan\alpha = \frac{1}{\lambda},$$

выбираем

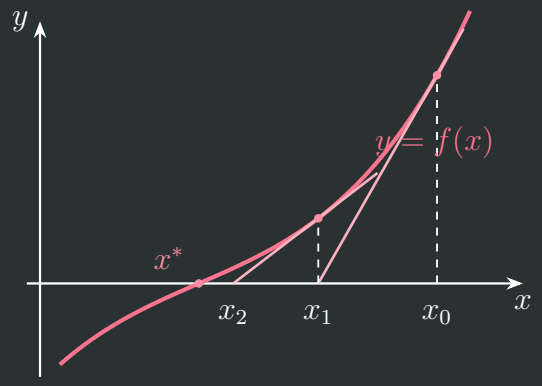
$$\lambda(x_n) = \frac{1}{f'(x_n)}.$$

Тогда итерационный процесс принимает вид

$$x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)}.$$

Это метод Ньютона, или метод Ньютона–Рафсона.

Геометрически на каждом шаге проводим касательную к графику $y = f(x)$ в точке $(x_n, f(x_n))$. Точка пересечения этой касательной с осью x даёт следующее приближение x_{n+1}.



Геометрическая схема метода Ньютона.

Квадратичная сходимость

Оценим погрешность вблизи простого корня x^*, для которого

$$f(x^*) = 0, \qquad f'(x^*) \neq 0.$$

Введём знаковую погрешность

$$R_n = x^* - x_n.$$

Тогда

$$x_n - x^* = -R_n.$$

Из формулы Ньютона

$$x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)}$$

получаем

$$\begin{aligned} R_{n+1} &= x^* - x_{n+1} \\ &= x^* - x_n + \frac{f(x_n)}{f'(x_n)} \\ &= R_n + \frac{f(x_n)}{f'(x_n)}. \end{aligned}$$

Разложим функцию около корня:

$$\begin{aligned} f(x_n) &\approx f(x^*) + f'(x^*)(x_n - x^*) + \frac{1}{2} f''(x^*)(x_n - x^*)^2 \\ &= -f'(x^*)R_n + \frac{1}{2} f''(x^*)R_n^2. \end{aligned}$$

Аналогично для производной

$$\begin{aligned} f'(x_n) &\approx f'(x^*) + f''(x^*)(x_n - x^*) \\ &= f'(x^*) - f''(x^*)R_n. \end{aligned}$$

Подставим эти выражения в формулу для R_{n+1}:

$$R_{n+1} \approx R_n + \frac{-f'(x^*)R_n + \frac{1}{2}f''(x^*)R_n^2}{f'(x^*) - f''(x^*)R_n}.$$

Приведём два слагаемых к общему знаменателю:

$$R_{n+1} \approx \frac{R_n\big(f'(x^*) - f''(x^*)R_n\big) - f'(x^*)R_n + \frac{1}{2}f''(x^*)R_n^2}{f'(x^*) - f''(x^*)R_n}$$

$$= \frac{-\frac{1}{2}f''(x^*)R_n^2}{f'(x^*) - f''(x^*)R_n}.$$

Вынесем $f'(x^*)$ из знаменателя:

$$R_{n+1} \approx -\frac{1}{2}\frac{f''(x^*)}{f'(x^*)}\frac{R_n^2}{1 - \dfrac{f''(x^*)}{f'(x^*)}R_n}.$$

Вблизи корня $|R_n|$ мало, поэтому

$$\left|\frac{f''(x^*)}{f'(x^*)}R_n\right| \ll 1.$$

Следовательно,

$$R_{n+1} \approx -\frac{1}{2}\frac{f''(x^*)}{f'(x^*)}R_n^2.$$

Для абсолютной погрешности

$$\delta_n = |R_n|$$

получаем

$$\delta_{n+1} \approx \frac{1}{2}\left|\frac{f''(x^*)}{f'(x^*)}\right|\delta_n^2.$$

Таким образом, погрешность следующего приближения пропорциональна квадрату предыдущей погрешности:

$$\delta_{n+1} \sim \delta_n^2.$$

Поэтому метод Ньютона обладает квадратичной сходимостью. При достаточно хорошем начальном приближении число верных знаков примерно удваивается после каждой итерации.

Недостатки метода

Метод Ньютона очень быстро сходится вблизи простого корня, но имеет два существенных недостатка.

Во-первых, он чувствителен к начальному приближению. Если x_0 выбрано вне области притяжения искомого корня, процесс может расходиться либо сойтись к другому корню.

Во-вторых, на каждом шаге необходимо вычислять производную

$$f'(x_n).$$

Последний недостаток приводит к методу секущих.

2.6 Метод секущих

В методе Ньютона заменим производную приближённым значением, полученным по двум последним точкам:

$$f'(x_n) \approx \frac{f(x_n) - f(x_{n-1})}{x_n - x_{n-1}}.$$

Подставляя эту оценку в формулу Ньютона,

$$\begin{aligned} x_{n+1} &= x_n - \frac{f(x_n)}{f'(x_n)} \\ &\approx x_n - \frac{f(x_n)}{\dfrac{f(x_n) - f(x_{n-1})}{x_n - x_{n-1}}} \\ &= x_n - f(x_n)\frac{x_n - x_{n-1}}{f(x_n) - f(x_{n-1})}. \end{aligned}$$

Итак,

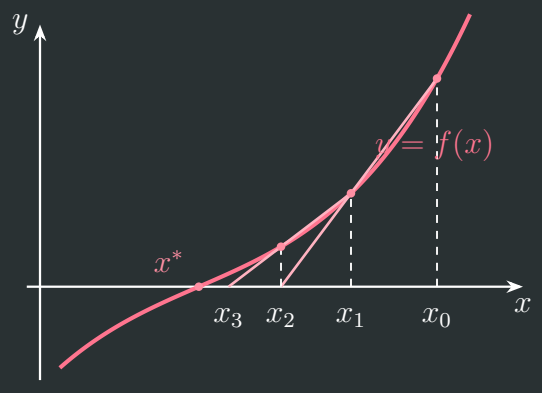
$$x_{n+1} = x_n - f(x_n)\frac{x_n - x_{n-1}}{f(x_n) - f(x_{n-1})}.$$

Этот процесс является двухшаговым: для нахождения x_{n+1} необходимо знать два предыдущих приближения x_{n-1} и x_n.

Геометрически вместо касательной используется секущая, проведённая через точки

$$(x_{n-1}, f(x_{n-1})) \qquad \text{и} \qquad (x_n, f(x_n)).$$

Её пересечение с осью x задаёт следующее приближение.



Геометрическая схема метода секущих.

Метод секущих не требует явного вычисления $f'(x)$ и обычно сходится быстрее метода простых итераций, хотя порядок его сходимости ниже, чем квадратичный порядок метода Ньютона.

Глава 3

Численное интегрирование

Методы прямоугольников, трапеций, Симпсона и Рунге

3.1 Постановка задачи

Рассмотрим задачу численного вычисления определённого интеграла

$$I = \int_a^b f(x)\,dx.$$

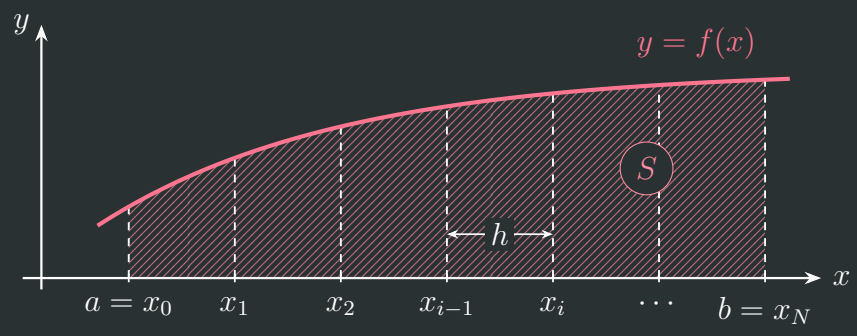
Геометрически интеграл соответствует площади под графиком функции $y = f(x)$ на отрезке $[a, b]$.

Разобьём интервал $[a, b]$ на N одинаковых частей и введём равномерную сетку

$$x_i = a + ih, \qquad i = 0, 1, \ldots, N,$$

где

$$h = \frac{b-a}{N} = \text{const}, \qquad x_0 = a, \qquad x_N = b.$$



Разбиение отрезка интегрирования на равномерную сетку.

Точное значение интеграла обозначим через I, а значение, полученное численным методом на сетке с шагом h, — через S_h. Тогда

$$I = S_h + R(h),$$

где

$$R(h) = I - S_h$$

— остаточный член, или погрешность численного интегрирования.

Квадратурные формулы как интерполяция

На каждом маленьком интервале

$$[x_{i-1}, x_i]$$

будем заменять исходную функцию $f(x)$ более простой функцией $\varphi(x)$, которую легко проинтегрировать.

Если использовать полином степени $n = 0$, то $\varphi(x)$ является постоянной. Возможны три естественных варианта:

$$\varphi(x) = f(x_{i-1}) \qquad \text{— метод левых прямоугольников,}$$

$$\varphi(x) = f(x_i) \qquad \text{— метод правых прямоугольников,}$$

$$\varphi(x) = f\left(\frac{x_{i-1} + x_i}{2}\right) \qquad \text{— формула средних.}$$

Если $n = 1$, функцию заменяем линейным интерполяционным полиномом, проходящим через значения на концах интервала:

$$\varphi(x) = \frac{x_i - x}{x_i - x_{i-1}} f(x_{i-1}) + \frac{x - x_{i-1}}{x_i - x_{i-1}} f(x_i).$$

Интегрирование этой прямой приводит к методу трапеций.

Если $n = 2$, используем квадратичную интерполяцию по трём точкам. В результате получаем формулу Симпсона.

3.2 Методы прямоугольников

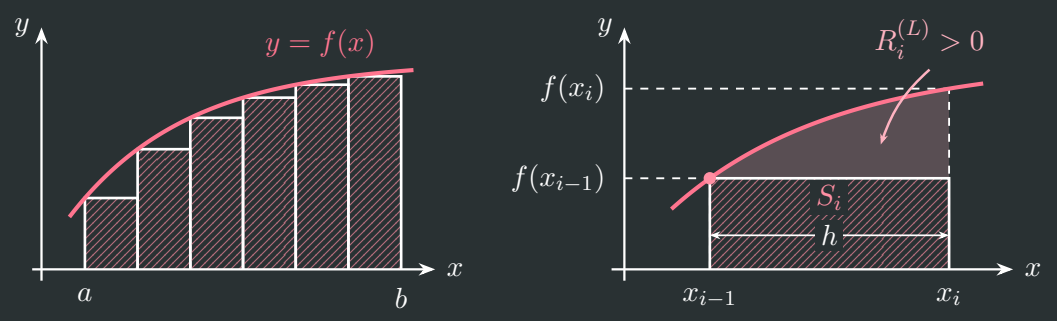
Метод левых прямоугольников

На каждом интервале $[x_{i-1}, x_i]$ заменим функцию постоянным значением в левой точке:

$$f(x) \approx f(x_{i-1}).$$

Тогда площадь под функцией на одном интервале приближается площадью прямоугольника $f(x_{i-1})h$, а на всём отрезке

$$\boxed{S_h^{(L)} = \sum_{i=1}^{N} f(x_{i-1})h}.$$



Метод левых прямоугольников.

Точное значение интеграла представим как сумму интегралов по ячейкам:

$$I = \int_a^b f(x)\,dx = \sum_{i=1}^{N} \int_{x_{i-1}}^{x_i} f(x)\,dx.$$

Поэтому

$$\begin{aligned} R_L(h) &= I - S_h^{(L)} \\ &= \sum_{i=1}^{N} \left[\int_{x_{i-1}}^{x_i} f(x)\,dx - f(x_{i-1})h \right]. \end{aligned}$$

Чтобы оценить погрешность, разложим функцию в ряд Тейлора около левой точки x_{i-1}:

$$f(x) = f(x_{i-1}) + f'(x_{i-1})(x - x_{i-1}) + \frac{1}{2} f''(x_{i-1})(x - x_{i-1})^2 + O(h^3).$$

Интегрируя по одному интервалу, получаем

$$\begin{aligned} \int_{x_{i-1}}^{x_i} f(x)\,dx &= f(x_{i-1})h + f'(x_{i-1}) \int_{x_{i-1}}^{x_i} (x - x_{i-1})\,dx + O(h^3) \\ &= f(x_{i-1})h + \frac{1}{2} f'(x_{i-1})h^2 + O(h^3). \end{aligned}$$

После вычитания площади прямоугольника остаётся локальная ошибка

$$R_i = \frac{1}{2} f'(x_{i-1})h^2 + O(h^3).$$

Суммируя по всей сетке,

$$\begin{aligned} R_L(h) &= \sum_{i=1}^{N} \left[\frac{1}{2} f'(x_{i-1})h^2 + O(h^3) \right] \\ &= \frac{h}{2} \sum_{i=1}^{N} f'(x_{i-1})h + O(h^2). \end{aligned}$$

При $h \to 0$ сумма переходит в интеграл:

$$\sum_{i=1}^{N} f'(x_{i-1})h \longrightarrow \int_a^b f'(x)\,dx.$$

Следовательно,

$$\boxed{R_L(h) = \frac{h}{2}\int_a^b f'(x)\,dx + O(h^2)} = O(h).$$

Таким образом, метод левых прямоугольников имеет первый порядок точности.

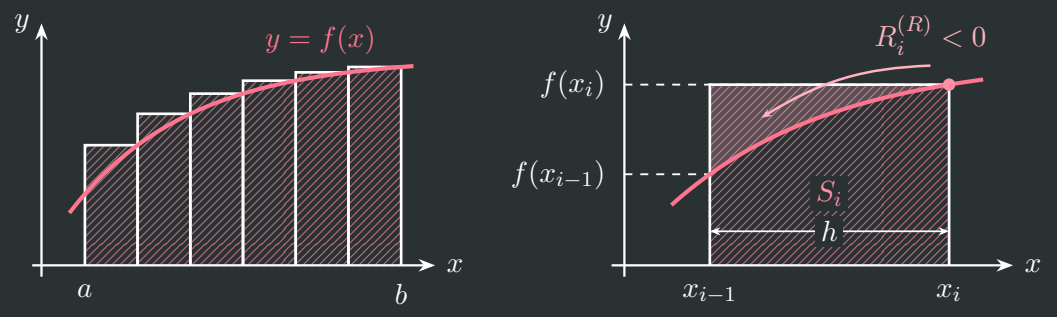
Метод правых прямоугольников

Теперь на каждом интервале используем значение функции в правом конце:

$$f(x) \approx f(x_i).$$

Получаем

$$\boxed{S_h^{(R)} = \sum_{i=1}^{N} f(x_i)h}.$$



Метод правых прямоугольников.

Разложение относительно правой точки x_i приводит к тому же по модулю, но противоположному по знаку главному члену погрешности:

$$\boxed{R_R(h) = -\frac{h}{2}\int_a^b f'(x)\,dx + O(h^2)} = O(h).$$

Следовательно, метод правых прямоугольников также имеет первый порядок точности. При этом

$$R_L(h) \simeq +\frac{h}{2}\int_a^b f'(x)\,dx, \qquad R_R(h) \simeq -\frac{h}{2}\int_a^b f'(x)\,dx.$$

Главные части погрешностей имеют одинаковый модуль и противоположные знаки. Это позволяет построить метод более высокого порядка точности.

3.3 Метод трапеций

Для левых и правых прямоугольников имеем

$$I = S_L + R_L(h), \qquad I = S_R + R_R(h).$$

Сложим эти равенства и разделим результат на два:

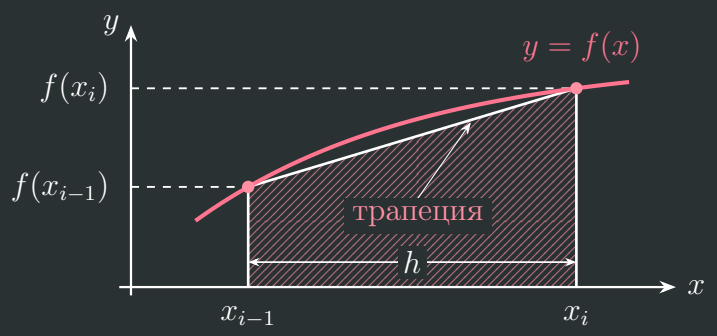
$$I = \frac{S_L + S_R}{2} + \frac{R_L(h) + R_R(h)}{2}.$$

Поскольку главные члены погрешностей порядка $O(h)$ имеют противоположные знаки, они сокращаются. В результате

$$I = \sum_{i=1}^{N} \frac{f(x_{i-1}) + f(x_i)}{2} h + O(h^2).$$

Таким образом, получаем квадратурную формулу трапеций

$$\boxed{S_h^{(T)} = \sum_{i=1}^{N} \frac{f(x_{i-1}) + f(x_i)}{2}\, h}.$$



На каждом интервале график функции заменяется хордой.

Погрешность метода трапеций

Обозначим середину i-го интервала через

$$c_i = \frac{x_{i-1} + x_i}{2}.$$

Тогда

$$x_{i-1} = c_i - \frac{h}{2}, \qquad x_i = c_i + \frac{h}{2}.$$

Разложим функцию около середины интервала:

$$f(x) = f(c_i) + f'(c_i)(x - c_i) + \frac{1}{2} f''(c_i)(x - c_i)^2 + O(h^3).$$

При интегрировании по симметричному промежутку линейный член исчезает:

$$\int_{-h/2}^{h/2} t\,dt = 0.$$

Поэтому

$$\begin{aligned}\int_{x_{i-1}}^{x_i} f(x)\,dx &= f(c_i)h + \frac{1}{2}f''(c_i)\int_{-h/2}^{h/2} t^2\,dt + O(h^5)\\ &= f(c_i)h + \frac{1}{24}f''(c_i)h^3 + O(h^5).\end{aligned}$$

Теперь разложим значения на концах интервала:

$$\begin{aligned}f\left(c_i - \frac{h}{2}\right) &= f(c_i) - \frac{h}{2}f'(c_i) + \frac{h^2}{8}f''(c_i) + O(h^3),\\ f\left(c_i + \frac{h}{2}\right) &= f(c_i) + \frac{h}{2}f'(c_i) + \frac{h^2}{8}f''(c_i) + O(h^3).\end{aligned}$$

Следовательно,

$$\frac{h}{2}\left[f(x_{i-1}) + f(x_i)\right] = f(c_i)h + \frac{1}{8}f''(c_i)h^3 + O(h^5).$$

Локальная погрешность равна

$$R_i^{(T)} = -\frac{1}{12}f''(c_i)h^3 + O(h^5).$$

После суммирования по всей сетке

$$\begin{aligned}R_T(h) &= -\frac{h^2}{12}\sum_{i=1}^{N} f''(c_i)h + O(h^4)\\ &= \boxed{-\frac{h^2}{12}\int_a^b f''(x)\,dx + O(h^4)}.\end{aligned}$$

Следовательно,

$$R_T(h) = O(h^2),$$

и метод трапеций имеет второй порядок точности.

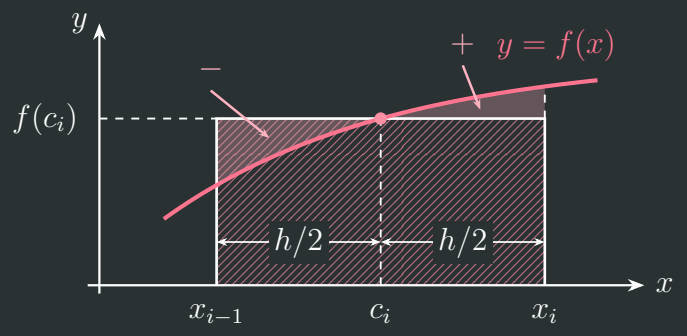
3.4 Формула средних

В методе средних функцию на каждом интервале заменяем её значением в центральной точке

$$c_i = \frac{x_{i-1} + x_i}{2}.$$

Получаем

$$\boxed{S_h^{(M)} = \sum_{i=1}^{N} f\left(\frac{x_{i-1} + x_i}{2}\right)h}.$$



Формула средних: высота прямоугольника берётся в центре интервала.

Остаточный член имеет вид

$$R_M(h) = \sum_{i=1}^{N} \left[\int_{x_{i-1}}^{x_i} f(x)\,dx - f(c_i)h \right].$$

Снова используем разложение около середины:

$$f(x) = f(c_i) + f'(c_i)(x - c_i) + \frac{1}{2} f''(c_i)(x - c_i)^2 + O(h^3).$$

Нечётный член исчезает при интегрировании, поэтому

$$\begin{aligned} \int_{x_{i-1}}^{x_i} f(x)\,dx - f(c_i)h &= \frac{1}{2} f''(c_i) \int_{-h/2}^{h/2} t^2\,dt + O(h^5) \\ &= \frac{1}{24} f''(c_i) h^3 + O(h^5). \end{aligned}$$

Суммируя по всем интервалам,

$$\begin{aligned} R_M(h) &= \frac{h^2}{24} \sum_{i=1}^{N} f''(c_i) h + O(h^4) \\ &= \boxed{\frac{h^2}{24} \int_a^b f''(x)\,dx + O(h^4)}. \end{aligned}$$

Следовательно,

$$R_M(h) = O(h^2),$$

то есть формула средних имеет второй порядок точности.

Сравним главные члены погрешностей формулы трапеций и формулы средних:

$$R_T(h) \simeq -\frac{h^2}{12} \int_a^b f''(x)\,dx, \qquad R_M(h) \simeq +\frac{h^2}{24} \int_a^b f''(x)\,dx.$$

Их знаки противоположны, причём

$$R_T(h) \simeq -2R_M(h).$$

3.5 Метод Симпсона

Используем найденное соотношение между погрешностями трапеций и средних. Имеем

$$I = S_T + R_T, \qquad I = S_M + R_M.$$

Умножим второе равенство на 2 и сложим с первым:

$$3I = S_T + 2S_M + R_T + 2R_M.$$

Но главные члены второго порядка взаимно уничтожаются:

$$R_T + 2R_M \simeq -\frac{h^2}{12}\int_a^b f''(x)\,dx + 2\cdot\frac{h^2}{24}\int_a^b f''(x)\,dx = 0.$$

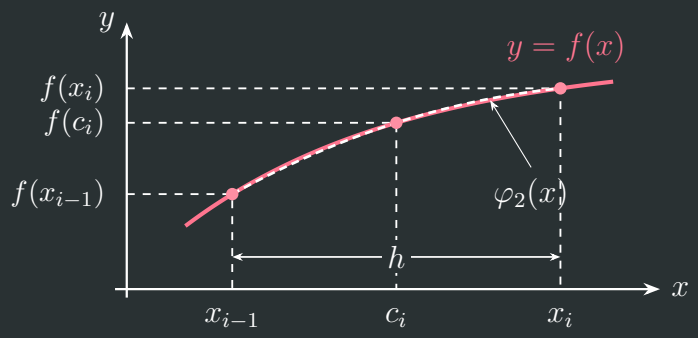
Следовательно,

$$I = \frac{S_T + 2S_M}{3} + O(h^4).$$

Подставляя формулы трапеций и средних, получаем

$$S_h^{(S)} = \frac{1}{3}\sum_{i=1}^{N}\left[2f\left(\frac{x_{i-1}+x_i}{2}\right) + \frac{f(x_{i-1})+f(x_i)}{2}\right]h$$

$$= \boxed{\sum_{i=1}^{N}\frac{f(x_{i-1}) + 4f\left(\dfrac{x_{i-1}+x_i}{2}\right) + f(x_i)}{6}\,h}.$$



В формуле Симпсона функция заменяется квадратичной интерполяцией по трём точкам.

Для остаточного члена формулы Симпсона получаем

$$\boxed{R_S(h) = -\frac{h^4}{2880}\int_a^b f^{(4)}(x)\,dx + O(h^6)}.$$

Следовательно,

$$R_S(h) = O(h^4),$$

и метод Симпсона имеет четвёртый порядок точности.

Замечание.

В этой записи $h = x_i - x_{i-1}$ — ширина целого интервала, на котором используются две крайние точки и его середина. Поэтому коэффициент в остаточном члене записан как $1/2880$.

3.6 Метод Рунге

Метод Рунге позволяет повысить порядок точности, используя результаты расчёта одной и той же величины на двух сетках с разными шагами.

Пусть численный метод имеет порядок точности p. Тогда результат на сетке с шагом h можно записать в виде

$$I = S(h) + Ch^p + O(h^{p+1}), \tag{3.1}$$

где $C = \text{const}$ относительно h.

Теперь изменим шаг сетки в r раз:

$$h \longrightarrow rh.$$

Для новой сетки имеем

$$I = S(rh) + C(rh)^p + O(h^{p+1}) = S(rh) + Cr^p h^p + O(h^{p+1}). \tag{3.2}$$

Умножим (3.1) на r^p:

$$r^p I = r^p S(h) + Cr^p h^p + O(h^{p+1}).$$

Теперь вычтем (3.2). Главный член погрешности $Cr^p h^p$ сокращается:

$$\begin{aligned} r^p I - I &= r^p S(h) - S(rh) + O(h^{p+1}), \\ (r^p - 1)I &= r^p S(h) - S(rh) + O(h^{p+1}). \end{aligned}$$

Отсюда получаем формулу Рунге

$$\boxed{I = \frac{r^p S(h) - S(rh)}{r^p - 1} + O(h^{p+1})}.$$

Таким образом, линейная комбинация результатов на двух сетках позволяет убрать главный член погрешности Ch^p.

Если обозначить уточнённое значение через $S_R(h)$, то

$$\boxed{S_R(h) = \frac{r^p S(h) - S(rh)}{r^p - 1}}.$$

Идея метода Рунге. Если известна структура главного члена погрешности $R(h) = Ch^p + O(h^{p+1})$, то два расчёта с шагами h и rh позволяют исключить неизвестную константу C и получить более точное приближение к интегралу.

Глава 4

Аппроксимация и интерполяция

Интерполяционные полиномы в форме Лагранжа и Ньютона

4.1 Задача интерполяции

Пусть функция $y(x)$ задана в $n+1$ точках, то есть известны значения

$$y(x_0) = y_0, \qquad y(x_1) = y_1, \qquad \ldots, \qquad y(x_n) = y_n.$$

Точки $x_0, x_1, \ldots, x_n$ называются узлами интерполяции. Требуется построить непрерывную интерполирующую функцию $f(x)$, совпадающую с заданной функцией во всех узлах:

$$\begin{cases} f(x_0) = y_0, \\ f(x_1) = y_1, \\ \quad \vdots \\ f(x_n) = y_n. \end{cases}$$

В задаче алгебраической интерполяции в качестве $f(x)$ ищем полином степени не выше n:

$$P_n(x) = a_0 + a_1 x + a_2 x^2 + \cdots + a_n x^n,$$

удовлетворяющий условиям

$$P_n(x_i) = y_i, \qquad i = 0, 1, \ldots, n. \tag{4.1}$$

4.2 Существование и единственность интерполяционного полинома

Теорема. Если все узлы попарно различны, то есть $x_i \neq x_j$ при $i \neq j$, задача алгебраической интерполяции имеет единственное решение среди полиномов степени не выше n.

Система для коэффициентов

Подставляя полином в условия (4.1), получаем $n+1$ линейное уравнение для $n+1$ неизвестного коэффициента:

$$\begin{cases} a_0 + a_1 x_0 + a_2 x_0^2 + \cdots + a_n x_0^n = y_0, \\ a_0 + a_1 x_1 + a_2 x_1^2 + \cdots + a_n x_1^n = y_1, \\ \qquad\qquad \vdots \\ a_0 + a_1 x_n + a_2 x_n^2 + \cdots + a_n x_n^n = y_n. \end{cases}$$

В матричной форме эта система записывается как

$$\underbrace{\begin{pmatrix} 1 & x_0 & x_0^2 & \cdots & x_0^n \\ 1 & x_1 & x_1^2 & \cdots & x_1^n \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & x_n^2 & \cdots & x_n^n \end{pmatrix}}_{A} \begin{pmatrix} a_0 \\ a_1 \\ \vdots \\ a_n \end{pmatrix} = \begin{pmatrix} y_0 \\ y_1 \\ \vdots \\ y_n \end{pmatrix}.$$

Она имеет единственное решение тогда и только тогда, когда $\det A \neq 0$.

Определитель Вандермонда

Определитель Вандермонда равен

$$V_n(x_0, \ldots, x_n) = \begin{vmatrix} 1 & x_0 & \cdots & x_0^n \\ 1 & x_1 & \cdots & x_1^n \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & \cdots & x_n^n \end{vmatrix} = \prod_{0 \le j < i \le n} (x_i - x_j). \tag{4.2}$$

Докажем формулу методом математической индукции. При $n = 1$ имеем

$$V_1(x_0, x_1) = \begin{vmatrix} 1 & x_0 \\ 1 & x_1 \end{vmatrix} = x_1 - x_0.$$

Предположим, что формула верна для $n = k$, и рассмотрим $n = k+1$. Последовательно, начиная с последнего столбца, вычтем из каждого столбца предыдущий, умноженный на x_0. Получим

$$V_{k+1} = \begin{vmatrix} 1 & 0 & 0 & \cdots & 0 \\ 1 & x_1 - x_0 & x_1(x_1 - x_0) & \cdots & x_1^k(x_1 - x_0) \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{k+1} - x_0 & x_{k+1}(x_{k+1} - x_0) & \cdots & x_{k+1}^k(x_{k+1} - x_0) \end{vmatrix}.$$

Разложим определитель по первой строке и вынесем из каждой оставшейся стро-

ки множитель $x_i - x_0$:

$$V_{k+1} = \prod_{i=1}^{k+1}(x_i - x_0)\begin{vmatrix} 1 & x_1 & \cdots & x_1^k \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{k+1} & \cdots & x_{k+1}^k \end{vmatrix}$$
$$= \prod_{i=1}^{k+1}(x_i - x_0) \prod_{1\le j<i\le k+1}(x_i - x_j)$$
$$= \prod_{0\le j<i\le k+1}(x_i - x_j).$$

Формула доказана.

Если все узлы различны, ни один множитель в (4.2) не равен нулю. Следовательно,

$$\det A \neq 0,$$

а значит, коэффициенты $a_0, \ldots, a_n$ определяются однозначно. Тем самым доказаны существование и единственность полинома $P_n(x)$.

4.3 Интерполяционный полином в форме Лагранжа

Будем искать полином в виде

$$P_n(x) = \sum_{i=0}^{n} y_i \varphi_i(x),$$

где базисные полиномы $\varphi_i(x)$ удовлетворяют условиям

$$\varphi_i(x_j) = \delta_{ij} = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

Полином $\varphi_i(x)$ должен обращаться в нуль во всех узлах, кроме x_i. Поэтому положим

$$\varphi_i(x) = C_i \prod_{\substack{j=0 \\ j\neq i}}^{n}(x - x_j).$$

Из условия $\varphi_i(x_i) = 1$ находим

$$C_i = \frac{1}{\prod\limits_{\substack{j=0 \\ j\neq i}}^{n}(x_i - x_j)}.$$

Таким образом, интерполяционный полином Лагранжа имеет вид

$$P_n(x) = \sum_{i=0}^{n} y_i \prod_{\substack{j=0 \\ j \neq i}}^{n} \frac{x - x_j}{x_i - x_j}. \tag{4.3}$$

Каждый базисный полином имеет степень n, поэтому степень их суммы не превосходит n. В узле x_i в сумме остаётся только слагаемое y_i.

Недостаток формы Лагранжа.

При добавлении нового узла приходится перестраивать все базисные полиномы. Для последовательного дополнения сетки удобнее форма Ньютона.

4.4 Разделённые разности

Пусть известны значения $y(x)$ в попарно различных узлах $x_0, \ldots, x_n$. Введём разделённые разности.

Разделённая разность нулевого порядка — само значение функции:

$$y^{(0)}(x_i) = y(x_i).$$

Разделённая разность первого порядка:

$$y^{(1)}(x_0, x_1) = \frac{y(x_0) - y(x_1)}{x_0 - x_1}.$$

Второго порядка:

$$y^{(2)}(x_0, x_1, x_2) = \frac{y^{(1)}(x_0, x_1) - y^{(1)}(x_1, x_2)}{x_0 - x_2}.$$

В общем случае

$$y^{(n)}(x_0, \ldots, x_n) = \frac{y^{(n-1)}(x_0, \ldots, x_{n-1}) - y^{(n-1)}(x_1, \ldots, x_n)}{x_0 - x_n}. \tag{4.4}$$

Замечание.

Здесь верхний индекс (n) при нескольких аргументах означает порядок разделённой разности. Производную функции в одной точке ниже будем записывать как $y^{(n)}(x)$.

Явная формула и симметрия

Теорема. Для попарно различных узлов справедлива формула

$$y^{(n)}(x_0, \ldots, x_n) = \sum_{i=0}^{n} \frac{y(x_i)}{\prod\limits_{\substack{j=0 \\ j \neq i}}^{n} (x_i - x_j)}.$$

Следовательно, разделённая разность является симметричной функцией своих аргументов: её значение не изменяется при перестановке узлов $x_0, \ldots, x_n$.

4.5 Интерполяционный полином в форме Ньютона

Последовательное понижение степени

Существование полинома $P_n(x)$ уже доказано. Разность $P_n(x) - P_n(x_0)$ обращается в нуль при $x = x_0$, поэтому делится на $x - x_0$ без остатка. Введём полином степени не выше $n-1$:

$$P_{n-1}^{(1)}(x, x_0) = \frac{P_n(x) - P_n(x_0)}{x - x_0}.$$

Деление полинома можно выполнить по схеме Горнера. Получаем

$$P_n(x) = P_n(x_0) + (x - x_0)P_{n-1}^{(1)}(x, x_0).$$

На следующем шаге аналогично определим

$$P_{n-2}^{(2)}(x, x_0, x_1) = \frac{P_{n-1}^{(1)}(x, x_0) - P_{n-1}^{(1)}(x_1, x_0)}{x - x_1}.$$

Здесь числитель снова делится на знаменатель без остатка, и

$$P_{n-1}^{(1)}(x, x_0) = P_{n-1}^{(1)}(x_1, x_0) + (x - x_1)P_{n-2}^{(2)}(x, x_0, x_1).$$

Продолжая процесс, на k-м шаге получаем

$$P_{n-k}^{(k)}(x, x_0, \ldots, x_{k-1}) = \frac{P_{n-k+1}^{(k-1)}(x, x_0, \ldots, x_{k-2}) - P_{n-k+1}^{(k-1)}(x_{k-1}, x_0, \ldots, x_{k-2})}{x - x_{k-1}}.$$

После n шагов остаётся постоянный полином $P_0^{(n)}$. Ещё одна разделённая разность равна нулю:

$$\frac{P_0^{(n)}(x, x_0, \ldots, x_{n-1}) - P_0^{(n)}(x_n, x_0, \ldots, x_{n-1})}{x - x_n} = 0.$$

Формула Ньютона

Последовательно подставляя полученные выражения, приходим к вложенной записи полинома:

$$\begin{aligned} P_n(x) = P_n(x_0) + (x - x_0)\Big[& P_{n-1}^{(1)}(x_0, x_1) \\ & + (x - x_1)\big[P_{n-2}^{(2)}(x_0, x_1, x_2) + \cdots \\ & \qquad + (x - x_{n-1})P_0^{(n)}(x_0, \ldots, x_n)\big]\Big]. \end{aligned}$$

Коэффициенты этой записи — разделённые разности P_n в узлах. Поскольку $P_n(x_i) = y(x_i)$, они совпадают с разделёнными разностями y. Получаем интерполяционную формулу Ньютона:

$$P_n(x) = y(x_0) + \sum_{k=1}^{n} y^{(k)}(x_0, \ldots, x_k) \prod_{j=0}^{k-1}(x - x_j). \tag{4.5}$$

В развёрнутом виде

$$\begin{aligned} P_n(x) = y(x_0) &+ y^{(1)}(x_0, x_1)(x - x_0) \\ &+ y^{(2)}(x_0, x_1, x_2)(x - x_0)(x - x_1) + \cdots \\ &+ y^{(n)}(x_0, \ldots, x_n)(x - x_0) \cdots (x - x_{n-1}). \end{aligned}$$

При добавлении нового узла x_{n+1} достаточно добавить одно слагаемое:

$$P_{n+1}(x) = P_n(x) + y^{(n+1)}(x_0, \ldots, x_{n+1}) \prod_{j=0}^{n} (x - x_j).$$

Уже вычисленные коэффициенты сохраняются, поэтому форма Ньютона удобна для добавления новых узлов.

4.6 Погрешность интерполяции

Интерполяционное приближение имеет вид $y_n(x) = P_n(x)$. Разность $y(x) - P_n(x)$ обращается в нуль во всех $n + 1$ узлах. Обозначим

$$\omega_{n+1}(x) = \prod_{i=0}^{n} (x - x_i).$$

Для x, не совпадающего с узлами, представим погрешность в виде

$$y(x) - P_n(x) = \omega_{n+1}(x) r(x).$$

Найдём выражение для $r(x)$.

Вывод остаточного члена

Зафиксируем точку $u \notin \{x_0, \ldots, x_n\}$ и введём вспомогательную функцию

$$g(x, u) = y(x) - P_n(x) - \omega_{n+1}(x) r(u).$$

Как функция переменной x, она имеет $n + 2$ различных нуля:

$$x_0, x_1, \ldots, x_n, u.$$

Пусть $y \in C^{n+1}(I)$, где отрезок I содержит все эти точки. Тогда g также непрерывно дифференцируема $n + 1$ раз по x. Последовательно применяя теорему Ролля, заключаем, что существует точка ξ между наименьшей и наибольшей из точек $x_0, \ldots, x_n, u$, в которой

$$\frac{\partial^{n+1} g}{\partial x^{n+1}}(\xi, u) = 0.$$

Поскольку степень P_n не выше n, а старший коэффициент ω_{n+1} равен единице,

$$\frac{\partial^{n+1} g}{\partial x^{n+1}}(x, u) = y^{(n+1)}(x) - (n + 1)!\, r(u).$$

Следовательно,

$$0 = y^{(n+1)}(\xi) - (n+1)!\, r(u), \qquad r(u) = \frac{y^{(n+1)}(\xi)}{(n+1)!}.$$

Возвращаясь к обозначению x для точки, в которой оценивается ошибка, получаем остаточный член интерполяции:

$$y(x) - P_n(x) = \frac{y^{(n+1)}(\xi)}{(n+1)!} \prod_{i=0}^{n} (x - x_i). \tag{4.6}$$

Точка ξ зависит от x. В самих узлах погрешность равна нулю.

Оценка погрешности на сетке

Если на рассматриваемом отрезке

$$\left|y^{(n+1)}(t)\right| \le C,$$

то из (4.6) следует

$$|y(x) - P_n(x)| \le \frac{C}{(n+1)!} \prod_{i=0}^{n} |x - x_i|.$$

Пусть узлы упорядочены и расстояние между соседними узлами имеет порядок h:

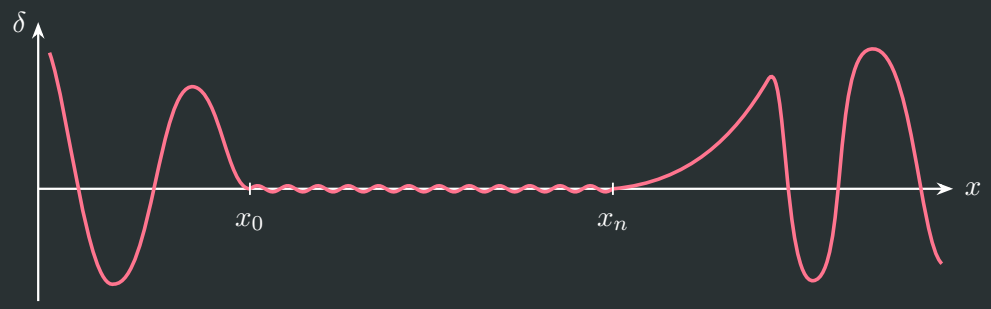
$$x_0 < x_1 < \cdots < x_n, \qquad |x_{i+1} - x_i| \sim h.$$

При фиксированном n и $x \in [x_0, x_n]$ каждый множитель $|x - x_i|$ имеет порядок $O(h)$. Если производная ограничена независимо от h, то

$$|y(x) - P_n(x)| = O(h^{n+1}).$$

Это оценка при сгущении локальной сетки с фиксированным числом узлов. Вне интервала $[x_0, x_n]$ произведение расстояний до узлов может быстро расти, и точность экстраполяции ухудшается.

Эффект Рунге



Схематическое поведение погрешности $\delta(x) = y(x) - P_n(x)$: малые колебания на участке интерполяции и рост ошибки за его пределами.

Замечание.

Эффект Рунге связан с тем, что при увеличении степени интерполяционного полинома на равномерной сетке могут усиливаться колебания и возрастать ошибка, в том числе у концов самого интервала интерполяции. Оценка $O(h^{n+1})$ при фиксированном n не означает сходимости при $n \to \infty$ на фиксированном отрезке.

Узлы Чебышёва

Остаточный член интерполяции содержит узловой множитель

$$\omega_{n+1}(x) = \prod_{i=0}^{n}(x - x_i), \qquad y(x) - P_n(x) = \frac{y^{(n+1)}(\xi)}{(n+1)!}\omega_{n+1}(x).$$

Поэтому при выборе узлов стремятся минимизировать величину

$$\max_{x\in[a,b]} \left|\prod_{i=0}^{n}(x - x_i)\right|.$$

На отрезке $[-1, 1]$ минимум достигается, если x_i — корни полинома Чебышёва T_{n+1}:

$$T_{n+1}(t) = \cos\big((n+1)\arccos t\big), \qquad t_i = \cos\frac{(2i+1)\pi}{2(n+1)}, \quad i = 0, \dots, n.$$

Эти узлы сгущаются у концов отрезка. На произвольном отрезке $[a, b]$ упорядочим их по возрастанию:

$$x_i = \frac{a+b}{2} - \frac{b-a}{2}\cos\frac{(2i+1)\pi}{2(n+1)}, \qquad i = 0, \dots, n.$$

Для такого выбора

$$\max_{x\in[a,b]} |\omega_{n+1}(x)| = \frac{(b-a)^{n+1}}{2^{2n+1}}.$$

Таким образом, узлы Чебышёва минимизируют максимум модуля узлового множителя и уменьшают соответствующую оценку погрешности.

4.7 Численное дифференцирование

Производные интерполяционного полинома

Пусть известны значения $y(x_i) = y_i$ в узлах $x_0, \dots, x_n$. Вспомним полином Ньютона:

$$P_n(x) = y(x_0) + \sum_{k=1}^{n} y^{(k)}(x_0, \dots, x_k) \prod_{j=0}^{k-1} (x - x_j).$$

При нескольких аргументах $y^{(k)}(x_0, \dots, x_k)$ означает разделённую разность, а $y^{(k)}(x)$ с одним аргументом — производную. Приближённые значения производных получаем дифференцированием P_n.

Введём локальную равномерную сетку с шагом $h = x_{i+1} - x_i$. При фиксированном числе близких узлов и ограниченных производных разложение по формуле Тейлора даёт

$$y(x) = P_n(x) + O(h^{n+1}), \qquad y^{(m)}(x) = P_n^{(m)}(x) + O(h^{n+1-m}), \quad 1 \le m \le n.$$

Для полинома степени m по $m+1$ узлам старший коэффициент равен разделённой разности порядка m, поэтому

$$P_m^{(m)}(x) = m!\, y^{(m)}(x_0, \dots, x_m),$$
$$y^{(m)}(x) = m!\, y^{(m)}(x_0, \dots, x_m) + O(h).$$

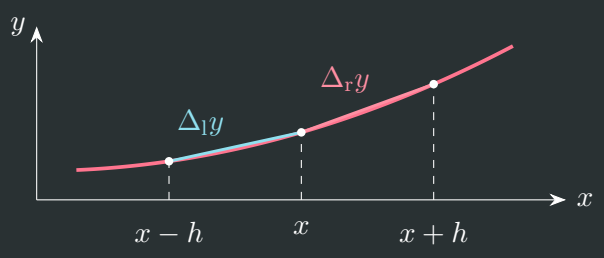
Первая производная: правая и левая разности

Правая разностная производная определяется как

$$\Delta_{\mathrm{r}} y(x) = \frac{y(x+h) - y(x)}{h}.$$

Это наклон секущей через точки с абсциссами x и $x+h$. Аналогично левая разностная производная равна

$$\Delta_{\mathrm{l}} y(x) = \frac{y(x) - y(x-h)}{h}.$$



Левая и правая разностные производные — наклоны секущих на соседних участках сетки.

Оценка погрешности первой производной

Погрешность правой разности равна $R_{\mathrm{r}}(h) = \Delta_{\mathrm{r}} y(x) - y'(x)$. Разложим функцию в ряд Тейлора:

$$y(x+h) = y(x) + hy'(x) + \frac{h^2}{2}y''(x) + \frac{h^3}{6}y'''(x) + O(h^4).$$

Подстановка даёт

$$R_{\mathrm{r}}(h) = \frac{h}{2}y''(x) + \frac{h^2}{6}y'''(x) + O(h^3) = O(h).$$

Для левой разности аналогично

$$R_{\mathrm{l}}(h) = \Delta_{\mathrm{l}} y(x) - y'(x) = -\frac{h}{2}y''(x) + \frac{h^2}{6}y'''(x) + O(h^3) = O(h).$$

Обе односторонние формулы имеют первый порядок точности.

Центральная разность

Усреднение левой и правой разностей устраняет член первого порядка:

$$\Delta_{\mathrm{c}} y(x) = \frac{\Delta_{\mathrm{r}} y(x) + \Delta_{\mathrm{l}} y(x)}{2} = \frac{y(x+h) - y(x-h)}{2h}.$$

Для достаточно гладкой функции погрешность равна

$$R_{\mathrm{c}}(h) = \Delta_{\mathrm{c}} y(x) - y'(x) = \frac{h^2}{6}y'''(x) + O(h^4) = O(h^2).$$

Центральная разность имеет второй порядок точности.

Вторая производная

По трём произвольным близким узлам

$$y''(x) = 2!\, y^{(2)}(x_0, x_1, x_2) + O(h).$$

На симметричной равномерной сетке $x_0 = x - h$, $x_1 = x$, $x_2 = x + h$ разделённая разность равна

$$\begin{aligned} y^{(2)}(x-h, x, x+h) &= \frac{y^{(1)}(x-h, x) - y^{(1)}(x, x+h)}{(x-h) - (x+h)} \\ &= \frac{y(x+h) - 2y(x) + y(x-h)}{2h^2}. \end{aligned}$$

Центральная формула и её разложение по Тейлору имеют вид

$$\Delta_2 y(x) = \frac{y(x+h) - 2y(x) + y(x-h)}{h^2},$$
$$\Delta_2 y(x) = y''(x) + \frac{h^2}{12}y^{(4)}(x) + O(h^4).$$

Благодаря симметрии сетки эта формула также имеет второй порядок точности.

Глава 5

Численное решение обыкновенных дифференциальных уравнений

Метод Эйлера и явный метод средней точки

5.1 Задача Коши и равномерная сетка

Рассмотрим задачу Коши для ОДУ первого порядка:

$$\begin{cases} u'(x) = f(x, u(x)), & x \in [a, b], \\ u(a) = u_0. \end{cases}$$

Функцию $u(x)$ будем считать точным решением. Значения численного решения на сетке обозначим через y_i. Для N равных шагов

$$h = \frac{b-a}{N}, \qquad x_i = a + ih, \qquad i = 0, \ldots, N, \qquad y_i \simeq u(x_i).$$

Производные точного решения

Если f достаточно гладкая, производные u можно выразить через f. По правилу дифференцирования сложной функции

$$\begin{aligned} u' &= f, \\ u'' &= f_x + f_u u' = f_x + f f_u, \\ u''' &= f_{xx} + 2 f f_{xu} + f^2 f_{uu} + f_x f_u + f (f_u)^2. \end{aligned}$$

Все значения f и её частных производных в этих формулах берутся в точке $(x, u(x))$.

5.2 Метод Эйлера

Разностная схема

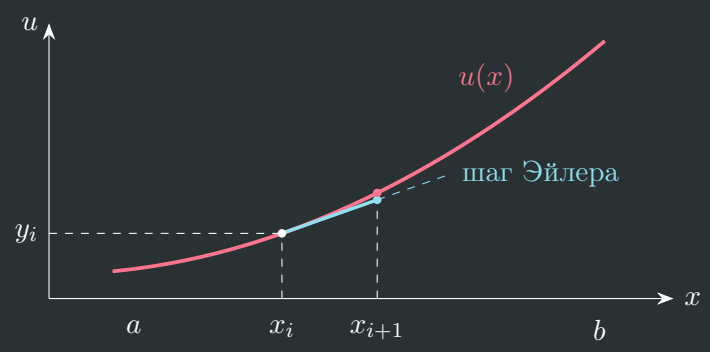
Заменим производную правой разностью и вычислим правую часть в начале шага:

$$\frac{y_{i+1} - y_i}{h} = f(x_i, y_i).$$

Получаем явную схему Эйлера:

$$\begin{cases} y_{i+1} = y_i + h f(x_i, y_i), & i = 0, \ldots, N-1, \\ y_0 = u_0. \end{cases}$$

На каждом шаге наклон решения заменяется наклоном касательной в начале этого шага.



Шаг метода Эйлера: переход вдоль касательной вместо движения по точной интегральной кривой.

Локальная погрешность

Разложим точное решение около x_i:

$$u(x_i + h) = u(x_i) + hu'(x_i) + \frac{h^2}{2}u''(x_i) + O(h^3).$$

Пусть в начале одного шага $y_i = u(x_i)$. Тогда

$$y_{i+1} = u(x_i) + hf(x_i, u(x_i)) = u(x_i) + hu'(x_i).$$

Погрешность одного шага равна

$$u(x_{i+1}) - y_{i+1} = \frac{h^2}{2}u''(x_i) + O(h^3).$$

Таким образом, локальная погрешность метода Эйлера имеет порядок $O(h^2)$.

Невязка и порядок аппроксимации

Введём разностный оператор

$$\Delta_h v_i = \frac{v_{i+1} - v_i}{h} - f(x_i, v_i).$$

Численная схема записывается как $\Delta_h y_i = 0$. Подстановка точного решения $u_i = u(x_i)$ в этот оператор даёт невязку:

$$\Psi_{h,i} = \Delta_h u_i = \frac{u(x_i + h) - u(x_i)}{h} - f(x_i, u(x_i)).$$

Невязка численной аппроксимации дифференциального уравнения — результат подстановки его точного решения в разностную схему. Если $\Psi_{h,i} = O(h^p)$, то схема аппроксимирует уравнение с порядком p.

Для метода Эйлера

$$\Psi_{h,i} = u'(x_i) + \frac{h}{2}u''(x_i) + O(h^2) - f(x_i, u(x_i))$$
$$= \frac{h}{2}u''(x_i) + O(h^2) = O(h).$$

Следовательно, схема Эйлера имеет первый порядок аппроксимации. Невязка отличается от погрешности одного шага множителем $1/h$.

Накопление погрешности

На фиксированном отрезке число шагов равно $N = (b-a)/h$. Для оценки накопления локальных ошибок необходимо учитывать их распространение между шагами. Предположим, что f удовлетворяет условию Липшица по u:

$$|f(x, v) - f(x, w)| \le L|v - w|.$$

Если $e_i = y_i - u(x_i)$ и локальная погрешность ограничена величиной Ch^2, то

$$|e_{i+1}| \le (1 + Lh)|e_i| + Ch^2, \qquad e_0 = 0.$$

При $L > 0$ отсюда следует

$$|e_i| \le \frac{Ch}{L}\big((1 + Lh)^i - 1\big) \le \frac{Ch}{L}\big(e^{L(b-a)} - 1\big) = O(h).$$

При $L = 0$ оценка принимает вид

$$|e_N| \le NCh^2 = C(b-a)h = O(h).$$

Таким образом, глобальная погрешность Эйлера на фиксированном отрезке имеет первый порядок по шагу h.

5.3 Модифицированный метод Эйлера

Интегральная форма уравнения

Интегрируя $u' = f(x, u)$ на одном шаге, получаем

$$u(x_{i+1}) = u(x_i) + \int_{x_i}^{x_{i+1}} f(x, u(x))\,dx.$$

Замена интеграла формулой левых прямоугольников даёт

$$u(x_{i+1}) = u(x_i) + hf(x_i, u(x_i)) + O(h^2),$$

то есть обычную схему Эйлера.

Чтобы повысить порядок точности, используем метод средних прямоугольников:

$$u(x_{i+1}) = u(x_i) + hf\left(x_i + \frac{h}{2}, u\left(x_i + \frac{h}{2}\right)\right) + O(h^3).$$

Значение решения в середине шага заранее неизвестно. Оценим его полушагом метода Эйлера:

$$y_{i+1/2} = y_i + \frac{h}{2}f(x_i, y_i).$$

Явная схема средней точки

Получаем модифицированный метод Эйлера:

$$\begin{cases} y_{i+1/2} = y_i + \dfrac{h}{2} f(x_i, y_i), \\ y_{i+1} = y_i + hf\left(x_i + \dfrac{h}{2}, y_{i+1/2}\right), \\ y_0 = u_0. \end{cases}$$

В одной формуле

$$y_{i+1} = y_i + hf\left(x_i + \frac{h}{2}, y_i + \frac{h}{2} f(x_i, y_i)\right).$$

Здесь правая часть вычисляется дважды: в начале шага и в приближённой средней точке.

Порядок точности

Если $y_i = u(x_i)$, то разложение f в средней точке даёт

$$f\left(x_i + \frac{h}{2}, u(x_i) + \frac{h}{2} f(x_i, u(x_i))\right) = f + \frac{h}{2}(f_x + f f_u) + O(h^2).$$

Следовательно,

$$y_{i+1} = u(x_i) + hu'(x_i) + \frac{h^2}{2} u''(x_i) + O(h^3).$$

Первые три члена совпадают с разложением точного решения. Поэтому локальная погрешность равна $O(h^3)$, невязка — $O(h^2)$, а глобальная погрешность при тех же условиях гладкости и Липшица — $O(h^2)$. Модифицированный метод Эйлера имеет второй порядок точности.

Невязка модифицированного метода Эйлера

В предыдущей лекции значение решения в середине шага заменялось полушагом Эйлера. Полученная схема

$$y_{i+1} = y_i + hf\left(x_i + \frac{h}{2}, y_i + \frac{h}{2}f(x_i, y_i)\right)$$

называется также явным методом средней точки. Проверим её порядок через невязку, то есть результат подстановки точного решения $u_i = u(x_i)$ в разностное уравнение:

$$\Psi_{h,i} = \frac{u_{i+1} - u_i}{h} - f\left(x_i + \frac{h}{2}, u_i + \frac{h}{2}f(x_i, u_i)\right).$$

Далее для краткости f, f_x и f_u без аргументов означают значения в точке (x_i, u_i). По формуле Тейлора

$$\frac{u_{i+1} - u_i}{h} = u_i' + \frac{h}{2}u_i'' + O(h^2),$$
$$f\left(x_i + \frac{h}{2}, u_i + \frac{h}{2}f\right) = f + \frac{h}{2}f_x + \frac{h}{2}ff_u + O(h^2).$$

Так как $u_i' = f$ и $u_i'' = f_x + ff_u$, члены нулевого и первого порядков сокращаются:

$$\Psi_{h,i} = u_i' - f + \frac{h}{2}\left(u_i'' - f_x - ff_u\right) + O(h^2) = O(h^2).$$

Следовательно, схема имеет второй порядок аппроксимации. Погрешность одного шага, начатого с точного значения, равна $h\Psi_{h,i} = O(h^3)$. Глобальная погрешность на фиксированном отрезке при условиях гладкости и Липшица имеет порядок $O(h^2)$.

5.4 Исправленный метод Эйлера

От формулы трапеций к схеме предиктор–корректор

Запишем точное приращение решения в интегральной форме:

$$u(x_{i+1}) - u(x_i) = \int_{x_i}^{x_{i+1}} f(x, u(x))\,dx.$$

Заменяя интеграл формулой трапеций, получаем

$$u(x_{i+1}) = u(x_i) + \frac{h}{2}\left[f(x_i, u(x_i)) + f(x_{i+1}, u(x_{i+1}))\right] + O(h^3).$$

Если перенести эту формулу непосредственно на сеточные значения, получится неявная схема: y_{i+1} входит в правую часть. Чтобы получить явный алгоритм, сначала предскажем значение на конце шага методом Эйлера, а затем используем этот прогноз для вычисления второго наклона:

$$\begin{cases} \widetilde{y}_{i+1} = y_i + hf(x_i, y_i), \\ y_{i+1} = y_i + \dfrac{h}{2}\left[f(x_i, y_i) + f(x_i + h, \widetilde{y}_{i+1})\right]. \end{cases}$$

Первая строка — предиктор, вторая — корректор. В одной формуле исправленный метод Эйлера записывается как

$$y_{i+1} = y_i + \frac{h}{2}\left[f(x_i, y_i) + f\big(x_i + h, y_i + hf(x_i, y_i)\big)\right].$$

Геометрически берётся среднее двух наклонов: в начале шага и в предсказанной конечной точке.

Проверка порядка

При $y_i = u_i$ разложение второго наклона даёт

$$f(x_i + h, u_i + hf) = f + h(f_x + ff_u) + O(h^2).$$

Поэтому

$$\begin{aligned} y_{i+1} &= u_i + \frac{h}{2}\left[2f + h(f_x + ff_u) + O(h^2)\right] \\ &= u_i + hu_i' + \frac{h^2}{2}u_i'' + O(h^3). \end{aligned}$$

Разложение совпадает с точным решением до членов порядка h^2. Исправленный метод Эйлера, как и метод средней точки, имеет второй порядок точности, но вычисляет второй наклон в другой точке.

5.5 Методы Рунге–Кутты второго порядка

Общая двухстадийная схема

Оба варианта Эйлера можно включить в одно семейство:

$$\begin{cases} k_1 = f(x_i, y_i), \\ k_2 = f(x_i + b_1 h, y_i + b_2 h k_1), \\ y_{i+1} = y_i + h(a_1 k_1 + a_2 k_2). \end{cases}$$

Величины k_1 и k_2 — стадии метода, то есть два значения правой части. Коэффициенты a_1, a_2, b_1, b_2 подбираются так, чтобы невязка была $O(h^2)$.

Подставим точное решение и разложим вторую стадию:

$$f(x_i + b_1 h, u_i + b_2 hf) = f + h(b_1 f_x + b_2 ff_u) + O(h^2).$$

Тогда невязка равна

$$\begin{aligned} \Psi_{h,i} &= \frac{u_{i+1} - u_i}{h} - a_1 f - a_2 f(x_i + b_1 h, u_i + b_2 hf) \\ &= (1 - a_1 - a_2)f + h\left(\frac{1}{2} - a_2 b_1\right) f_x + h\left(\frac{1}{2} - a_2 b_2\right) ff_u + O(h^2). \end{aligned}$$

Чтобы сокращение происходило для произвольной гладкой правой части, коэффициенты перед независимыми выражениями должны обращаться в нуль:

$$a_1 + a_2 = 1, \qquad a_2 b_1 = \frac{1}{2}, \qquad a_2 b_2 = \frac{1}{2}.$$

Это условия второго порядка.

Однопараметрическое семейство

Положим $a_2 = \alpha \neq 0$. Тогда

$$a_1 = 1 - \alpha, \qquad b_1 = b_2 = \frac{1}{2\alpha},$$

и схема принимает вид

$$y_{i+1} = y_i + h\left[(1-\alpha) f(x_i, y_i) + \alpha f\left(x_i + \frac{h}{2\alpha}, y_i + \frac{h}{2\alpha} f(x_i, y_i)\right)\right].$$

Таким образом, второй порядок не определяет метод единственным образом. В частности,

- $\alpha = 1$: $a_1 = 0$, $b_1 = b_2 = 1/2$ — модифицированный метод Эйлера, или явный метод средней точки;
- $\alpha = 1/2$: $a_1 = a_2 = 1/2$, $b_1 = b_2 = 1$ — исправленный метод Эйлера;
- $\alpha = 3/4$: $a_1 = 1/4$, $b_1 = b_2 = 2/3$ — метод Ралстона.

Последний вариант имеет вид

$$y_{i+1} = y_i + \frac{h}{4}\left[f(x_i, y_i) + 3f\left(x_i + \frac{2h}{3}, y_i + \frac{2h}{3} f(x_i, y_i)\right)\right].$$

Замечание.

В лекции выбор $\alpha = 3/4$ отмечен как вариант с минимизацией ошибки. Здесь речь идёт о выборе коэффициентов по оценке ведущего члена локальной погрешности. Универсального минимума фактической ошибки для любой функции f это не означает: все перечисленные схемы имеют второй порядок, а коэффициент ошибки зависит от уравнения.

5.6 Классический метод Рунге–Кутты четвёртого порядка

Четыре вычисления правой части

Формула Симпсона использует значения подынтегральной функции в начале, середине и конце интервала:

$$\int_{x_i}^{x_i+h} g(x)\,dx \simeq \frac{h}{6}\left[g(x_i) + 4g\left(x_i + \frac{h}{2}\right) + g(x_i + h)\right].$$

При решении ОДУ функция $g(x) = f(x, u(x))$ зависит от неизвестного решения. Поэтому значения на промежуточных точках приходится строить последовательно.

Классическая схема РК4:

$$\begin{cases} k_1 = f(x_i, y_i), \\ k_2 = f\left(x_i + \dfrac{h}{2}, y_i + \dfrac{h}{2}k_1\right), \\ k_3 = f\left(x_i + \dfrac{h}{2}, y_i + \dfrac{h}{2}k_2\right), \\ k_4 = f(x_i + h, y_i + hk_3), \\ y_{i+1} = y_i + \dfrac{h}{6}(k_1 + 2k_2 + 2k_3 + k_4). \end{cases}$$

Здесь k_j имеют смысл производных; множитель h в них не включён. На один шаг требуются четыре вычисления f.

Вторая стадия оценивает наклон в середине шага по прогнозу из k_1, третья уточняет этот наклон по k_2, а четвёртая оценивает наклон на конце шага по k_3. После этого наклоны складываются с весами $1, 2, 2, 1$.

Связь с квадратурой и порядок точности

Если правая часть зависит только от x, то $k_2 = k_3 = f(x_i + h/2)$, и РК4 действительно превращается в формулу Симпсона. При зависимости от u две средние стадии различны: простая подстановка одного прогноза в формулу Симпсона сама по себе не доказывает четвёртый порядок.

Для достаточно гладкой f согласование разложения схемы с рядом Тейлора точного решения до h^4 даёт локальную погрешность $O(h^5)$. На фиксированном отрезке при условии Липшица глобальная погрешность равна $O(h^4)$. Поэтому РК4 имеет четвёртый порядок точности.

5.7 Многошаговый метод Адамса–Башфорта

Интерполяция правой части по предыдущим шагам

В одношаговых методах новое значение строится по текущему y_i, хотя внутри шага может вычисляться несколько стадий. В многошаговых методах используются также предыдущие сеточные значения.

Пусть уже известны y_i, y_{i-1} и y_{i-2} на равномерной сетке. Обозначим

$$F_j = f(x_j, y_j).$$

Построим квадратичный полином по трём последним значениям правой части. В форме Ньютона он записывается как

$$P_2(x) = F_i + F[x_i, x_{i-1}](x - x_i) + F[x_i, x_{i-1}, x_{i-2}](x - x_i)(x - x_{i-1}),$$

где квадратные скобки обозначают разделённые разности. На равномерной сетке

$$F[x_i, x_{i-1}] = \frac{F_i - F_{i-1}}{h},$$
$$F[x_i, x_{i-1}, x_{i-2}] = \frac{F_i - 2F_{i-1} + F_{i-2}}{2h^2}.$$

Полином строится по прошлым точкам, а интегрируется на следующем интервале $[x_i, x_{i+1}]$. Это экстраполяция правой части на один шаг.

Интегрирование полинома

Заменим $f(x, u(x))$ в интегральной формуле полиномом $P_2(x)$:

$$y_{i+1} = y_i + \int_{x_i}^{x_i+h} P_2(x)\,dx.$$

Положим $s = x - x_i$. Тогда $x - x_{i-1} = s + h$, и

$$\int_0^h ds = h, \qquad \int_0^h s\,ds = \frac{h^2}{2},$$
$$\int_0^h s(s+h)\,ds = \frac{h^3}{3} + \frac{h^3}{2} = \frac{5h^3}{6}.$$

Отсюда

$$\begin{aligned} y_{i+1} &= y_i + hF_i + \frac{h^2}{2}F[x_i, x_{i-1}] + \frac{5h^3}{6}F[x_i, x_{i-1}, x_{i-2}] \\ &= y_i + h\left[F_i + \frac{1}{2}(F_i - F_{i-1}) + \frac{5}{12}(F_i - 2F_{i-1} + F_{i-2})\right]. \end{aligned}$$

Собирая коэффициенты, получаем

$$y_{i+1} = y_i + \frac{h}{12}\left(23F_i - 16F_{i-1} + 5F_{i-2}\right), \qquad i \geq 2.$$

Это трёхшаговый метод Адамса–Башфорта третьего порядка.

Погрешность и начало расчёта

Для точной функции $F(x) = f(x, u(x))$ остаток квадратичной интерполяции на интервале следующего шага имеет порядок $O(h^3)$:

$$F(x) - P_2(x) = \frac{F^{(3)}(\xi)}{3!}(x - x_i)(x - x_{i-1})(x - x_{i-2}).$$

После интегрирования на отрезке длины h получаем локальную погрешность $O(h^4)$. При гладкости правой части и достаточно точных начальных значениях глобальная погрешность составляет $O(h^3)$.

Для старта недостаточно одного условия $y_0 = u_0$: нужны ещё y_1 и y_2. Их можно найти, например, двумя шагами РК4. После запуска достаточно одного нового вычисления F_i на шаг: два предыдущих значения сохраняются из прошлых шагов.

5.8 Устойчивость решения и численной схемы

Устойчивость по Ляпунову

Рассмотрим задачу Коши

$$u' = f(x, u), \qquad u(a) = u_0.$$

Пусть $u(x)$ — её решение, а $v(x)$ — решение того же уравнения с немного изменённым начальным значением. Решение u называется устойчивым по Ляпунову, если для любого $\varepsilon > 0$ существует $\delta > 0$ такое, что

$$\|v(a) - u(a)\| < \delta \quad \Longrightarrow \quad \|v(x) - u(x)\| < \varepsilon \quad \text{для всех } x \geq a.$$

Иными словами, достаточно малое начальное возмущение остаётся малым на всём последующем промежутке. Здесь $\|\cdot\|$ обозначает норму; для одного уравнения это обычный модуль.

Если, кроме устойчивости, для достаточно близких начальных данных выполняется

$$\|v(x) - u(x)\| \longrightarrow 0, \qquad x \longrightarrow \infty,$$

то решение называется асимптотически устойчивым.

Линейная система и собственные значения

Для системы с постоянной матрицей

$$\frac{d\boldsymbol{u}}{dx} = A\boldsymbol{u}, \qquad \boldsymbol{u}(a) = \boldsymbol{u}_0$$

возмущение $\boldsymbol{\delta} = \boldsymbol{v} - \boldsymbol{u}$ подчиняется тому же уравнению:

$$\boldsymbol{\delta}' = A\boldsymbol{\delta}, \qquad \boldsymbol{\delta}(x) = e^{A(x-a)}\boldsymbol{\delta}(a).$$

Если $\boldsymbol{q}_j$ — собственный вектор A с собственным значением μ_j, то соответствующая мода изменяется как $e^{\mu_j(x-a)}$. Поэтому условие

$$\operatorname{Re}\mu_j < 0 \quad \text{для всех } j$$

обеспечивает асимптотическую устойчивость линейной системы. Если хотя бы одно собственное значение имеет положительную вещественную часть, соответствующее возмущение растёт.

Замечание.

Случай $\operatorname{Re}\mu_j = 0$ требует отдельного анализа: жордановы блоки могут давать степенной рост даже без положительной вещественной части собственных значений.

Численная схема также должна корректно переносить малые возмущения данных. В отличие от непрерывного уравнения, их распространение зависит ещё и от шага h и от выбранного метода. В следующей лекции это исследуется на затухающем линейном уравнении.

5.9 Устойчивость явной и неявной схем Эйлера

Тестовое уравнение

Рассмотрим одну затухающую моду линейной системы:

$$u' = -\lambda u, \qquad u(0) = u_0, \qquad \lambda > 0.$$

Её точное решение

$$u(x) = u_0 e^{-\lambda x}$$

стремится к нулю. Возмущение начальных данных также убывает как $e^{-\lambda x}$. Численный метод должен воспроизводить это затухание.

Для схемы, которая на этом уравнении имеет вид

$$y_{i+1} = q(\lambda h) y_i,$$

величина q называется множителем усиления. Если $\widetilde{y}_i = y_i + \delta_i$, то

$$\widetilde{y}_{i+1} = q(y_i + \delta_i), \qquad \delta_{i+1} = q\delta_i, \qquad \delta_i = q^i \delta_0.$$

Поэтому $|q| \le 1$ означает, что начальное возмущение не возрастает, а при $|q| < 1$ оно затухает.

Явная схема: ограничение на шаг

Для явного метода Эйлера

$$\frac{y_{i+1} - y_i}{h} = -\lambda y_i \quad \Longrightarrow \quad y_{i+1} = (1 - \lambda h) y_i.$$

Следовательно,

$$q_{\text{явн}} = 1 - \lambda h, \qquad \delta_{i+1} = (1 - \lambda h)\delta_i.$$

Чтобы ошибка не росла, необходимо

$$|1 - \lambda h| \le 1 \quad \Longleftrightarrow \quad 0 \le \lambda h \le 2.$$

При положительном шаге получаем условие устойчивости

$$0 < h \le \frac{2}{\lambda}.$$

При $0 < \lambda h < 1$ приближения убывают без смены знака, при $\lambda h = 1$ следующее значение равно нулю, а при $1 < \lambda h < 2$ знак чередуется, но модуль убывает. На границе $\lambda h = 2$ множитель равен -1: возмущение не затухает. При $\lambda h > 2$ схема неустойчива.

Замечание.

Устойчивость не гарантирует точности. Даже при $|q| < 1$ численное решение может заметно отличаться от $e^{-\lambda x}$. В частности, чередование знака отсутствует у точного решения с положительным u_0.

Условная и безусловная устойчивость

Схема называется условно устойчивой, если условие устойчивости выполняется лишь при ограничении на шаг. Явная схема Эйлера на рассматриваемом уравнении требует $h \le 2/\lambda$.

Если схема устойчива при любом $h > 0$ для данного класса задач, говорят о безусловной устойчивости. В записи лекции для этого также используется выражение «абсолютная устойчивость при любом шаге».

Неявная схема Эйлера

В неявной схеме правая часть вычисляется на новом слое:

$$y_{i+1} = y_i + hf(x_{i+1}, y_{i+1}).$$

Для тестового уравнения получаем

$$\begin{aligned} y_{i+1} &= y_i - \lambda h y_{i+1}, \\ (1+\lambda h) y_{i+1} &= y_i, \\ y_{i+1} &= \frac{y_i}{1+\lambda h}. \end{aligned}$$

Возмущение изменяется по закону

$$\delta_{i+1} = \frac{\delta_i}{1+\lambda h}.$$

При $\lambda > 0$ и любом $h > 0$

$$0 < q_{\text{неявн}} = \frac{1}{1+\lambda h} < 1.$$

Следовательно, неявный метод Эйлера безусловно устойчив на затухающем тестовом уравнении.

Решение неявного уравнения на каждом шаге

В общем случае формула для y_{i+1} не разрешается явно. На каждом шаге нужно решить уравнение

$$G(v) = v - y_i - hf(x_{i+1}, v) = 0.$$

Простейший вариант — простые итерации:

$$y_{i+1}^{(k+1)} = y_i + hf(x_{i+1}, y_{i+1}^{(k)}), \qquad k = 0, 1, \dots.$$

Индекс i нумерует узлы сетки, а k — внутренние итерации. Начальным приближением может служить y_i или явный прогноз Эйлера.

Если f удовлетворяет условию Липшица по второму аргументу с константой L, то достаточное условие сжатия этой итерации — $hL < 1$. Для $f = -\lambda u$ ошибка внутренней итерации умножается на $-h\lambda$, и требуется $h\lambda < 1$.

Замечание.

Устойчивость схемы и сходимость внутренней итерации — разные условия. Неявная схема Эйлера устойчива на тестовом уравнении при любом шаге, однако выбранный способ решения неявного уравнения может потребовать ограничения h. Для больших шагов используют, например, метод Ньютона или прямое решение линейной системы.

5.10 Жёсткие системы дифференциальных уравнений

Разные масштабы затухания

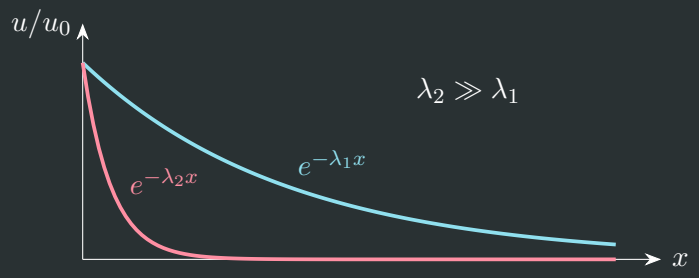
Пусть после выделения собственных мод линейная система содержит уравнения

$$u_j' = -\lambda_j u_j, \qquad \lambda_j > 0.$$

Каждая компонента затухает на своём характерном масштабе

$$\tau_j = \frac{1}{\lambda_j}.$$

Если $\max_j \lambda_j / \min_j \lambda_j$ велико, то в системе одновременно присутствуют быстро и медленно затухающие моды. Это характерный пример жёсткой системы.



Быстрая мода почти исчезает раньше, чем существенно меняется медленная. Ограничение устойчивости явной схемы продолжает определяться быстрым масштабом.

Почему явная схема требует малого шага

Для устойчивости явного метода Эйлера каждая мода должна удовлетворять $h\lambda_j \le 2$. Поэтому

$$h \le \frac{2}{\lambda_{\max}}, \qquad \lambda_{\max} = \max_j \lambda_j.$$

Но интересующая динамика может происходить на медленном масштабе $1/\lambda_{\min}$. Даже когда быстрая компонента стала очень малой, слишком большой шаг будет усиливать возмущения этой компоненты, в том числе ошибки округления.

Например, для $\lambda_1 = 1$ и $\lambda_2 = 1000$ явная схема требует $h \le 0.002$, хотя медленная компонента меняется на масштабе порядка единицы. На отрезке длины 1 приходится делать не менее 500 шагов уже по условию устойчивости.

Неявная схема позволяет выбирать шаг по требованиям точности медленной динамики, а не только по быстрому масштабу затухания. Это объясняет её пользу при решении жёстких задач.

Глава 6

Численные методы линейной алгебры

Метод Гаусса и прогонка для трёхдиагональных систем

6.1 Система линейных алгебраических уравнений

Рассмотрим систему линейных алгебраических уравнений

$$A\boldsymbol{x} = \boldsymbol{b}, \qquad \det A \neq 0,$$

где

$$A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix}, \qquad \boldsymbol{x} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}, \qquad \boldsymbol{b} = \begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{pmatrix}.$$

Матрица A и правая часть $\boldsymbol{b}$ заданы. Требуется найти вектор неизвестных $\boldsymbol{x}$. Условие $\det A \neq 0$ обеспечивает существование и единственность решения.

6.2 Метод Гаусса

Идея исключения неизвестных

Метод Гаусса состоит из двух этапов. На прямом ходе последовательно исключают неизвестные из нижних строк и приводят систему к верхнетреугольному виду:

$$\widetilde{A}\boldsymbol{x} = \widetilde{\boldsymbol{b}}, \qquad \widetilde{A} = \begin{pmatrix} \widetilde{a}_{11} & \widetilde{a}_{12} & \cdots & \widetilde{a}_{1n} \\ 0 & \widetilde{a}_{22} & \cdots & \widetilde{a}_{2n} \\ \vdots & \ddots & \ddots & \vdots \\ 0 & \cdots & 0 & \widetilde{a}_{nn} \end{pmatrix}.$$

На обратном ходе неизвестные находят снизу вверх: сначала x_n, затем x_{n-1} и так далее до x_1.

Прямой ход: один шаг алгоритма

Пусть первые $k-1$ столбцов под диагональю уже обнулены. Для каждой строки $i = k+1, \ldots, n$ вычислим множитель

$$m_{ik} = \frac{a_{ik}}{a_{kk}}.$$

Из строки i вычитаем строку k, умноженную на m_{ik}:

$$\begin{aligned} a_{ij} &\leftarrow a_{ij} - m_{ik}a_{kj}, && j = k+1, \dots, n, \\ b_i &\leftarrow b_i - m_{ik}b_k, \\ a_{ik} &\leftarrow 0. \end{aligned}$$

Здесь используются текущие, уже преобразованные коэффициенты. Множитель m_{ik} нужно сохранить до обнуления a_{ik}. Одинаковое преобразование применяется к матрице и правой части, поэтому множество решений системы не меняется.

Пример нескольких шагов

Рассмотрим систему

$$\begin{cases} 2x_1 + x_2 - x_3 = 1, \\ 4x_1 + x_2 + x_3 = 7, \\ -2x_1 + 2x_2 + x_3 = 4. \end{cases}$$

На первом шаге опорный элемент $a_{11} = 2$. Множители равны $m_{21} = 2$ и $m_{31} = -1$:

$$\left(\begin{array}{ccc|c} 2 & 1 & -1 & 1 \\ 4 & 1 & 1 & 7 \\ -2 & 2 & 1 & 4 \end{array}\right) \longrightarrow \left(\begin{array}{ccc|c} 2 & 1 & -1 & 1 \\ 0 & -1 & 3 & 5 \\ 0 & 3 & 0 & 5 \end{array}\right).$$

На втором шаге $a_{22} = -1$, $m_{32} = -3$. Прибавляя к третьей строке вторую, умноженную на 3, получаем

$$\left(\begin{array}{ccc|c} 2 & 1 & -1 & 1 \\ 0 & -1 & 3 & 5 \\ 0 & 0 & 9 & 20 \end{array}\right).$$

Теперь система имеет треугольный вид.

Обратный ход

Последнее уравнение содержит только x_n:

$$x_n = \frac{\widetilde{b}_n}{\widetilde{a}_{nn}}.$$

После нахождения $x_{i+1}, \dots, x_n$ из строки i получаем

$$x_i = \frac{\widetilde{b}_i - \sum\limits_{j=i+1}^{n} \widetilde{a}_{ij} x_j}{\widetilde{a}_{ii}}, \qquad i = n-1, \dots, 1.$$

В приведённом примере

$$x_3 = \frac{20}{9}, \qquad x_2 = 3x_3 - 5 = \frac{5}{3}, \qquad x_1 = \frac{1 - x_2 + x_3}{2} = \frac{7}{9}.$$

Опорный элемент и стоимость

Элемент a_{kk}, на который делят при исключении, называется опорным. Даже при $\det A \neq 0$ он может оказаться нулевым без перестановок строк. Например, у невырожденной матрицы $\left(\begin{smallmatrix} 0 & 1 \\ 1 & 1 \end{smallmatrix}\right)$ первый диагональный элемент равен нулю.

При частичном выборе главного элемента на шаге k выбирают строку $p \geq k$, для которой $|a_{pk}|$ максимально, и меняют местами строки p и k вместе с элементами правой части. Это позволяет избежать деления на нуль и уменьшить влияние малых опорных элементов на ошибки округления.

Для плотной матрицы прямой ход требует $O(n^3)$ операций, обратный — $O(n^2)$. Если матрица имеет специальную структуру, её можно использовать для уменьшения стоимости решения.

6.3 Метод прогонки для трёхдиагональной системы

Структура системы

Трёхдиагональная матрица имеет ненулевые элементы только на главной диагонали и на двух соседних:

$$A = \begin{pmatrix} b_1 & c_1 & 0 & \cdots & 0 \\ a_2 & b_2 & c_2 & \ddots & \vdots \\ 0 & a_3 & b_3 & \ddots & 0 \\ \vdots & \ddots & \ddots & \ddots & c_{n-1} \\ 0 & \cdots & 0 & a_n & b_n \end{pmatrix}.$$

Чтобы не путать главную диагональ b_i с правой частью, последнюю здесь обозначим через d_i. Система имеет вид

$$a_i x_{i-1} + b_i x_i + c_i x_{i+1} = d_i, \qquad i = 1, \ldots, n,$$

где $a_1 = 0$ и $c_n = 0$, то есть отсутствующие крайние слагаемые опускаются.

Метод прогонки, или алгоритм Томаса, представляет собой метод Гаусса с учётом этой структуры. При исключении достаточно изменять одну диагональ и правую часть.

Прямой ход прогонки

Начнём с первой строки:

$$\widetilde{b}_1 = b_1, \qquad \widetilde{d}_1 = d_1.$$

Чтобы исключить x_{i-1} из строки i, используем уже преобразованную строку $i-1$:

$$\widetilde{b}_{i-1} x_{i-1} + c_{i-1} x_i = \widetilde{d}_{i-1}.$$

Множитель исключения равен

$$m_i = \frac{a_i}{\widetilde{b}_{i-1}}.$$

Вычитая предыдущую строку, умноженную на m_i, получаем

$$\widetilde{b}_i = b_i - \frac{a_i c_{i-1}}{\widetilde{b}_{i-1}},$$
$$\widetilde{d}_i = d_i - \frac{a_i \widetilde{d}_{i-1}}{\widetilde{b}_{i-1}}, \qquad i = 2, \ldots, n.$$

Поддиагональный элемент обнуляется, а верхняя диагональ c_i остаётся без изменения. В результате система становится двухдиагональной:

$$\widetilde{b}_i x_i + c_i x_{i+1} = \widetilde{d}_i.$$

Обратный ход прогонки

В последней строке нет x_{n+1}, поэтому

$$x_n = \frac{\widetilde{d}_n}{\widetilde{b}_n}.$$

Далее движемся справа налево:

$$x_i = \frac{\widetilde{d}_i - c_i x_{i+1}}{\widetilde{b}_i}, \qquad i = n-1, n-2, \ldots, 1.$$

В отличие от общего обратного хода Гаусса, здесь для нахождения x_i используется только одно уже найденное значение x_{i+1}. На каждой строке выполняется фиксированное число действий, поэтому прогонка требует $O(n)$ операций и $O(n)$ памяти.

Замечание.

Формулы требуют ненулевых знаменателей $\widetilde{b}_i$. Одной невырожденности исходной матрицы для прогонки без перестановок недостаточно. Достаточное условие отсутствия нулевых опорных элементов — строгое диагональное преобладание

$$|b_i| > |a_i| + |c_i| \qquad \text{для всех } i.$$

Это достаточное, а не необходимое условие применимости алгоритма.

Откуда возникают трёхдиагональные матрицы

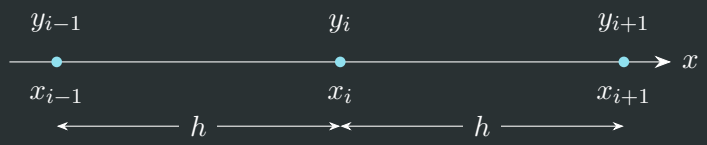
Такие системы появляются при разностной аппроксимации второй производной. Например, уравнение диффузии

$$\frac{\partial u}{\partial t} = D \frac{\partial^2 u}{\partial x^2}, \qquad D > 0,$$

в стационарном случае сводится к $u''(x) = 0$. На равномерной сетке вторая производная заменяется формулой

$$\frac{y_{i+1} - 2y_i + y_{i-1}}{h^2} = 0.$$

Каждое уравнение связывает только три соседних значения.



Трёхточечный шаблон второй производной: строка матрицы содержит коэффициенты при y_{i-1}, y_i, y_{i+1}.

Пусть заданы граничные значения $y_0 = U_L$ и $y_{n+1} = U_R$, а неизвестны $y_1, \dots, y_n$. После умножения уравнений на $-h^2$ и переноса граничных значений вправо получаем

$$\begin{pmatrix} 2 & -1 & 0 & \cdots & 0 \\ -1 & 2 & -1 & \ddots & \vdots \\ 0 & \ddots & \ddots & \ddots & 0 \\ \vdots & \ddots & -1 & 2 & -1 \\ 0 & \cdots & 0 & -1 & 2 \end{pmatrix} \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_{n-1} \\ y_n \end{pmatrix} = \begin{pmatrix} U_L \\ 0 \\ \vdots \\ 0 \\ U_R \end{pmatrix}.$$

Во внутренних строках правая часть нулевая, но в крайних строках в неё входят известные граничные значения.

Для этой матрицы $\widetilde{b}_1 = 2$ и

$$\widetilde{b}_i = 2 - \frac{1}{\widetilde{b}_{i-1}} = \frac{i+1}{i} > 0.$$

Поэтому прогонка работает без нулевых знаменателей, хотя во внутренних строках диагональное преобладание нестрогое.

6.4 Степенной метод

Оценки собственных значений по итерациям

После установления итерационного процесса отношение норм соседних приближений даёт оценку собственного значения.

В степенном методе $\vec{x}^{(k+1)} = A\vec{x}^{(k)}$, и

$$|\lambda_1| \simeq \frac{\|\vec{x}^{(k+1)}\|}{\|\vec{x}^{(k)}\|},$$

где λ_1 — наибольшее по модулю собственное значение.

В обратном степенном методе $\vec{x}^{(k+1)} = A^{-1}\vec{x}^{(k)}$. Наибольшее по модулю собственное значение матрицы A^{-1} равно $1/\lambda_n$, где λ_n — наименьшее по модулю собственное значение A:

$$\frac{1}{|\lambda_n|} \simeq \frac{\|\vec{x}^{(k+1)}\|}{\|\vec{x}^{(k)}\|}.$$

В методе обратных итераций со сдвигом $\vec{x}^{(k+1)} = \left(A - \lambda_i^{(0)}E\right)^{-1}\vec{x}^{(k)}$, где $\lambda_i^{(0)}$ — начальное приближение к λ_i. Процесс сходится к собственному значению, ближайшему к сдвигу:

$$\frac{1}{\left|\lambda_i - \lambda_i^{(0)}\right|} \simeq \frac{\|\vec{x}^{(k+1)}\|}{\|\vec{x}^{(k)}\|} \quad \Longrightarrow \quad \lambda_i \simeq \lambda_i^{(0)} \pm \frac{\|\vec{x}^{(k)}\|}{\|\vec{x}^{(k+1)}\|}.$$

Отношение норм определяет только модуль. Знак поправки определяется тем, сохраняет ли $\vec{x}^{(k+1)}$ направление $\vec{x}^{(k)}$ или меняет его на противоположное.

6.5 Метод вращений Якоби

Идея метода

Пусть A — вещественная симметричная матрица. Тогда существует ортогональная матрица O, $O^TO = E$, приводящая A к диагональному виду:

$$\Lambda = O^TAO = \operatorname{diag}(\lambda_1, \ldots, \lambda_n).$$

На диагонали Λ стоят собственные значения A, а столбцы O — соответствующие собственные векторы.

Метод Якоби строит O итерационно, как произведение элементарных вращений. Каждое вращение обнуляет один внедиагональный элемент.

Шаг итерации

Пусть $A^{(k)}$ — приближение к диагональной матрице Λ на k-й итерации, $A^{(0)} = A$. Выберем наибольший по модулю внедиагональный элемент:

$$\left|a_{i_kj_k}^{(k)}\right| = \max_{i<j}\left|a_{ij}^{(k)}\right|,$$

где i_k и j_k — номер строки и номер столбца максимального элемента на k-й итерации. Благодаря симметрии достаточно просматривать элементы над диагональю.

Следующее приближение получаем преобразованием

$$A^{(k+1)} = V_{i_k j_k}^T A^{(k)} V_{i_k j_k},$$

где $V_{i_k j_k}$ — матрица вращения в плоскости координат i_k, j_k на угол θ_k. Она совпадает с единичной матрицей всюду, кроме четырёх элементов на пересечениях строк и столбцов с номерами i_k и j_k:

$$V_{i_k j_k} = \begin{pmatrix} 1 & & & & & & \\ & \ddots & & & & & \\ & & \cos\theta_k & \cdots & -\sin\theta_k & & \leftarrow i_k \\ & & \vdots & \ddots & \vdots & & \\ & & \sin\theta_k & \cdots & \cos\theta_k & & \leftarrow j_k \\ & & & & & \ddots & \\ & & & & & & 1 \end{pmatrix}$$

Матрица $V_{i_k j_k}$ ортогональна, поэтому преобразование сохраняет симметрию и собственные значения.

Выбор угла поворота

Угол θ_k выбираем так, чтобы элемент на месте (i_k, j_k) обратился в нуль и матрица $A^{(k+1)}$ стала ближе к диагональной. Непосредственное перемножение даёт

$$a_{i_k j_k}^{(k+1)} = \bigl(\cos^2\theta_k - \sin^2\theta_k\bigr) a_{i_k j_k}^{(k)} + \cos\theta_k \sin\theta_k \bigl(a_{j_k j_k}^{(k)} - a_{i_k i_k}^{(k)}\bigr) = 0.$$

Так как $\cos^2\theta - \sin^2\theta = \cos 2\theta$ и $2\cos\theta\sin\theta = \sin 2\theta$, отсюда

$$\operatorname{tg} 2\theta_k = \frac{2a_{i_k j_k}^{(k)}}{a_{i_k i_k}^{(k)} - a_{j_k j_k}^{(k)}} \quad\Longrightarrow\quad \theta_k = \frac{1}{2}\operatorname{arctg}\frac{2a_{i_k j_k}^{(k)}}{a_{i_k i_k}^{(k)} - a_{j_k j_k}^{(k)}}.$$

При $a_{i_k i_k}^{(k)} = a_{j_k j_k}^{(k)}$ берут $\theta_k = \pm\pi/4$ со знаком $a_{i_k j_k}^{(k)}$.

Замечание.

Обнулённый элемент на следующих шагах может снова стать ненулевым. Однако сумма квадратов внедиагональных элементов при каждом вращении уменьшается ровно на $2\bigl(a_{i_k j_k}^{(k)}\bigr)^2$, поэтому матрицы $A^{(k)}$ сходятся к диагональной.

Собственные значения и векторы

Раскроем последовательность преобразований:

$$\begin{aligned} A^{(k+1)} &= V_{i_k j_k}^T A^{(k)} V_{i_k j_k} = V_{i_k j_k}^T V_{i_{k-1} j_{k-1}}^T A^{(k-1)} V_{i_{k-1} j_{k-1}} V_{i_k j_k} = \dots \\ &= \underbrace{V_{i_k j_k}^T \cdots V_{i_1 j_1}^T}_{\simeq O^T} \, A \, \underbrace{V_{i_1 j_1} \cdots V_{i_k j_k}}_{\simeq O}. \end{aligned}$$

Итерации продолжают, пока внедиагональные элементы не станут меньше заданной точности ε. Тогда $A^{(k+1)}$ практически диагональна, и

- собственные значения — это диагональные элементы $A^{(k+1)}$;
- собственные векторы — это столбцы матрицы $V_{i_1 j_1} \cdots V_{i_k j_k} \simeq O$.

Глава 7

Решение уравнения теплопроводности

Явная, неявная схемы и схема Кранка–Николсон

7.1 Разностная схема и её свойства

Невязка и порядок аппроксимации

Пусть $L_h y = f$ — численная схема решения краевой задачи для функции $y(x,t)$ с граничными условиями

$$\begin{cases} y(0,t) = g_0(t), \\ y(L,t) = g_1(t) \end{cases}$$

и начальным условием $y(x,0) = u_0(x)$. Здесь h и τ — шаги сетки по пространству и по времени.

Невязкой $\psi_{h,\tau}$ численной аппроксимации дифференциального уравнения называют результат подстановки точного решения u дифференциального уравнения в численную аппроксимацию:

$$\psi_{h,\tau} = L_h u - f.$$

Говорят, что численная схема аппроксимирует дифференциальное уравнение с порядком p по пространству и s по времени, если

$$\psi_{h,\tau} = O(h^p + \tau^s).$$

Устойчивость

Разностная схема называется устойчивой, если существуют h_0, τ_0 и δ такие, что при всех $h < h_0$, $\tau < \tau_0$ и любом возмущении $\|\varepsilon\| < \delta$ решение возмущённой задачи

$$L_h \tilde{y} = f + \varepsilon$$

удовлетворяет оценке

$$\|\tilde{y} - y\| < C\|\varepsilon\|.$$

Малое возмущение правой части приводит к малому изменению решения.

Если схема устойчива при любых h и τ ($h_0, \tau_0 \to \infty$), то она абсолютно устойчива. Если схема устойчива только при определённых соотношениях h и τ, то она условно устойчива.

Сходимость

Теорема. Если разностная схема аппроксимирует дифференциальное уравнение с порядком точности p по пространству и s по времени и схема устойчива, то имеет место оценка

$$\|u - y\| < C_1 h^p + C_2 \tau^s.$$

Таким образом, аппроксимация и устойчивость вместе обеспечивают сходимость численного решения к точному.

7.2 Уравнение теплопроводности

Постановка задачи

Уравнение теплопроводности (диффузии) имеет вид

$$\frac{\partial u}{\partial t} = a\frac{\partial^2 u}{\partial x^2} + f(x,t,u),$$

где a — коэффициент диффузии (температуропроводности). Функция u — это температура T в уравнении теплопроводности или концентрация n в уравнении диффузии.

Решение ищем в области

$$0 \le x \le 1, \qquad 0 \le t \le T.$$

Отрезок $[0, L]$ приводится к $[0, 1]$ заменой переменных.

Задаётся начальное условие

$$u(x, 0) = u_0(x)$$

и граничные условия на концах отрезка. Граничные условия I рода (Дирихле) задают значения функции:

$$\begin{cases} u(0,t) = g_0(t), \\ u(1,t) = g_1(t). \end{cases}$$

Граничные условия II рода (Неймана) задают значения производной, то есть поток:

$$\begin{cases} \dfrac{\partial u}{\partial x}(0,t) = g_0(t), \\ \dfrac{\partial u}{\partial x}(1,t) = g_1(t). \end{cases}$$

Переход к однородным граничным условиям

От неоднородных граничных условий можно перейти к однородным, выделив из решения известную функцию, которая сама удовлетворяет граничным условиям.

Условия I рода

Положим

$$u(x,t) = v(x,t) + (1-x)g_0(t) + xg_1(t).$$

Тогда

$$\begin{aligned} x=0: &\quad u(0,t) = v(0,t) + g_0(t) = g_0(t) \implies v(0,t) = 0, \\ x=1: &\quad u(1,t) = v(1,t) + g_1(t) = g_1(t) \implies v(1,t) = 0. \end{aligned}$$

Условия II рода

Ищем добавку в виде квадратичного полинома по x:

$$u(x,t) = v(x,t) + \alpha\frac{x^2}{2} + \beta x.$$

Потребуем $v'_x = 0$ на обеих границах:

$$\begin{cases} u'_x\big|_{x=0} = v'_x\big|_{x=0} + \alpha\cdot 0 + \beta = g_0(t), \\ u'_x\big|_{x=1} = v'_x\big|_{x=1} + \alpha + \beta = g_1(t), \end{cases} \qquad \implies \quad \alpha = g_1 - g_0, \qquad \beta = g_0.$$

Следовательно,

$$u(x,t) = v(x,t) + \frac{x^2}{2}\big[g_1(t) - g_0(t)\big] + xg_0(t).$$

Замечание.

Добавка зависит от t и, для условий II рода, не является линейной по x. Поэтому функция v удовлетворяет тому же уравнению с изменённой правой частью:

$$\frac{\partial v}{\partial t} = a\frac{\partial^2 v}{\partial x^2} + \tilde{f}, \qquad \tilde{f} = f - \frac{\partial w}{\partial t} + a\frac{\partial^2 w}{\partial x^2},$$

где $w = u - v$ — выделенная добавка. Начальное условие также пересчитывается: $v(x,0) = u_0(x) - w(x,0)$.

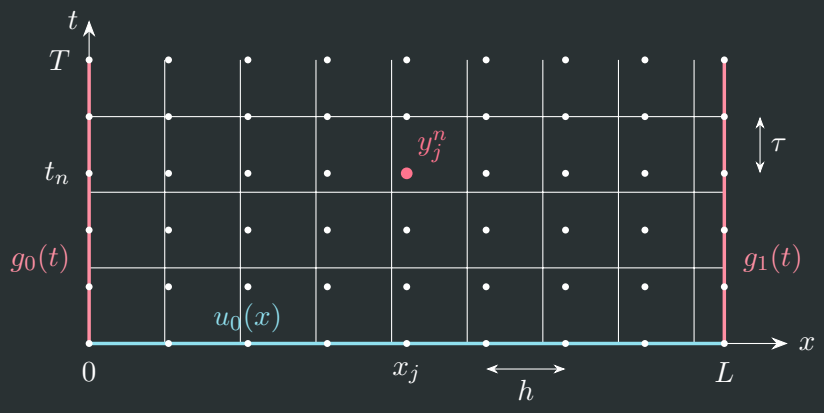
7.3 Конечно-разностная аппроксимация

Сетка

В области $0 \le x \le L$, $0 \le t \le T$ введём равномерную сетку:

$$x_j = jh, \quad h = \frac{L}{N}, \quad 0 \le j \le N; \qquad t_n = n\tau, \quad \tau = \frac{T}{M}, \quad 0 \le n \le M.$$

Значение численного решения в узле обозначим $y_j^n \simeq u(x_j, t_n)$: номер шага по времени пишется сверху, номер узла по пространству — снизу.



Равномерная сетка: на нижнем слое задано начальное условие, на боковых границах — граничные условия.

Явная схема

Заменим производные разностями:

$$\frac{\partial u}{\partial t} \to \frac{y_j^{n+1} - y_j^n}{\tau}, \qquad \frac{\partial^2 u}{\partial x^2} \to \frac{y_{j+1}^n - 2y_j^n + y_{j-1}^n}{h^2}.$$

Пусть $a = 1$, $f = 0$, то есть

$$\frac{\partial u}{\partial t} = \frac{\partial^2 u}{\partial x^2}.$$

Вторую производную по x можно взять как на n-м, так и на $(n+1)$-м временном слое. Выбор n-го слоя даёт явную схему:

$$\frac{y_j^{n+1} - y_j^n}{\tau} = \frac{y_{j+1}^n - 2y_j^n + y_{j-1}^n}{h^2}.$$

Значение y_j^{n+1} на новом слое выражается явно через три известных значения на предыдущем слое.

Неявная схема

Если вторую производную по x взять на $(n+1)$-м слое, получаем неявную схему:

$$\frac{y_j^{n+1} - y_j^n}{\tau} = \frac{y_{j+1}^{n+1} - 2y_j^{n+1} + y_{j-1}^{n+1}}{h^2}.$$

Каждое уравнение связывает три неизвестных значения нового слоя, поэтому на каждом шаге по времени решается система с трёхдиагональной матрицей, например методом прогонки.

Схема Кранка–Николсон

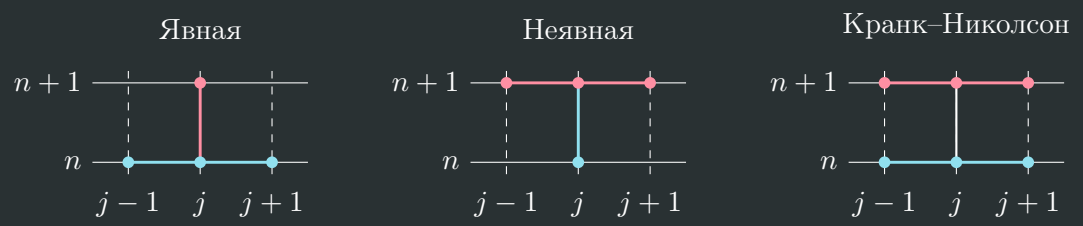
Полусумма явной и неявной аппроксимаций второй производной даёт схему Кранка–Николсон:

$$\frac{y_j^{n+1} - y_j^n}{\tau} = \frac{1}{2}\,\frac{y_{j+1}^n - 2y_j^n + y_{j-1}^n}{h^2} + \frac{1}{2}\,\frac{y_{j+1}^{n+1} - 2y_j^{n+1} + y_{j-1}^{n+1}}{h^2}.$$

Эта схема имеет порядок аппроксимации $O(\tau^2 + h^2)$.

Шаблоны схем

Набор узлов, которые входят в одно разностное уравнение, называется шаблоном схемы.



Шаблоны схем: голубые узлы лежат на известном слое n, розовые — на новом слое $n+1$.

7.4 Порядок аппроксимации

Рассмотрим уравнение с $a = 1$, $f = 0$. Подставим в разностные схемы точное решение u и разложим все значения по формуле Тейлора в узле (x_j, t_n). Производные без верхнего индекса берутся в этом узле.

Явная схема

Невязка явной схемы равна

$$\psi_{h,\tau} = L_h u - f = \frac{u_j^{n+1} - u_j^n}{\tau} - \frac{u_{j+1}^n - 2u_j^n + u_{j-1}^n}{h^2}.$$

Разложения по времени и по пространству:

$$u_j^{n+1} = u_j^n + \frac{\partial u}{\partial t}\tau + \frac{\partial^2 u}{\partial t^2}\frac{\tau^2}{2} + O(\tau^3),$$
$$u_{j\pm1}^n = u_j^n \pm \frac{\partial u}{\partial x}h + \frac{\partial^2 u}{\partial x^2}\frac{h^2}{2} \pm \frac{\partial^3 u}{\partial x^3}\frac{h^3}{3!} + \frac{\partial^4 u}{\partial x^4}\frac{h^4}{4!} + O(h^5).$$

При сложении u_{j+1}^n и u_{j-1}^n нечётные члены сокращаются:

$$\frac{u_{j+1}^n - 2u_j^n + u_{j-1}^n}{h^2} = \frac{\partial^2 u}{\partial x^2} + \frac{h^2}{12}\frac{\partial^4 u}{\partial x^4} + O(h^4).$$

Подставляя, получаем

$$\begin{aligned}\psi_{h,\tau} &= \frac{\partial u}{\partial t} + \frac{\partial^2 u}{\partial t^2}\frac{\tau}{2} - \frac{\partial^2 u}{\partial x^2} - \frac{h^2}{12}\frac{\partial^4 u}{\partial x^4} + O(\tau^2 + h^4) \\ &= \frac{\tau}{2}\frac{\partial^2 u}{\partial t^2} - \frac{h^2}{12}\frac{\partial^4 u}{\partial x^4} + O(\tau^2 + h^4) = O(\tau + h^2).\end{aligned}$$

Здесь $\dfrac{\partial u}{\partial t} - \dfrac{\partial^2 u}{\partial x^2} = 0$, так как u — решение дифференциального уравнения. Явная схема имеет первый порядок точности по t и второй порядок по x.

Неявная схема

Для неявной схемы пространственная разность берётся на слое $n+1$:

$$\psi_{h,\tau} = \frac{\partial u}{\partial t} + \frac{\partial^2 u}{\partial t^2}\frac{\tau}{2} - \left[\frac{\partial^2 u^{n+1}}{\partial x^2} + \frac{h^2}{12}\frac{\partial^4 u^{n+1}}{\partial x^4}\right] + O(\tau^2 + \tau h^2 + h^4).$$

Перенесём вторую производную с нового слоя в узел (x_j, t_n):

$$\frac{\partial^2 u^{n+1}}{\partial x^2} = \frac{\partial^2}{\partial x^2}\left(u + \tau\frac{\partial u}{\partial t}\right) + O(\tau^2) = \frac{\partial^2 u}{\partial x^2} + \tau\frac{\partial}{\partial t}\frac{\partial^2 u}{\partial x^2} + O(\tau^2) = \frac{\partial^2 u}{\partial x^2} + \tau\frac{\partial^2 u}{\partial t^2} + O(\tau^2).$$

В последнем переходе использовано уравнение $\dfrac{\partial^2 u}{\partial x^2} = \dfrac{\partial u}{\partial t}$. Тогда

$$\begin{aligned}\psi_{h,\tau} &= \frac{\partial u}{\partial t} + \frac{\tau}{2}\frac{\partial^2 u}{\partial t^2} - \frac{\partial^2 u}{\partial x^2} - \tau\frac{\partial^2 u}{\partial t^2} - \frac{h^2}{12}\frac{\partial^4 u}{\partial x^4} + O(\tau^2 + \tau h^2 + h^4)\\ &= -\frac{\tau}{2}\frac{\partial^2 u}{\partial t^2} - \frac{h^2}{12}\frac{\partial^4 u}{\partial x^4} + O(\tau^2 + \tau h^2 + h^4) = O(\tau + h^2).\end{aligned}$$

Неявная схема также имеет первый порядок точности по t и второй порядок по x.

Схема Кранка–Николсон

Невязка схемы Кранка–Николсон равна полусумме невязок явной и неявной схем. Главные члены по времени у них равны $\pm\dfrac{\tau}{2}\dfrac{\partial^2 u}{\partial t^2}$ и при усреднении сокращаются:

$$\psi_{h,\tau} = -\frac{h^2}{12}\frac{\partial^4 u}{\partial x^4} + O(\tau^2 + \tau h^2 + h^4) = O(\tau^2 + h^2).$$

Отсюда второй порядок точности по t и по x.